Predicting the Outcome of Soccer Matches Using Machine Learning and Statistical Analysis

Matheus Peixoto Ribeiro Vieira - 22.1.4104
Pedro Henrique R. L. de Oliveira - 22.1.4022

Introdução e Motivação

- A previsão de resultados de partidas de futebol tem sido uma tarefa complexa para cientistas de dados, frequentemente associada a baixas taxas de precisão.

- A principal dificuldade está na etapa de engenharia de *features* para encontrar relações úteis no dados que ajudem a ter uma melhor precisão.

- Esse trabalho propõe uma abordagem híbrida, combinando aprendizado de máquina com modelo estatístico, buscando uma melhoria na precisão.

Objetivos do Trabalho

- Desenvolver dois modelos híbridos para prever resultados de futebol.
  - O primeiro dá pesos iguais ao aprendizado de máquina e à análise estatística.
  - O segundo classifica as previsões em “fraco” e “forte” e aplica um pós-processamento de acordo com isso.
- Extrair novas features para o conjunto de dados.

Métricas usadas

- Acurácia.
- Ranked Probability Score (RPS): Compara a distribuição de probabilidade com os resultados obtidos, considerando o valor real e sua importância ordinal.
    - Como temos a ordem de importância vitória > empate > derrota, seu uso é adequado.
    - Quanto menor o seu valor, melhor.

Hipóteses

- Além disso, o trabalho busca também testar duas hipóteses relacionadas à engenharia de features:
    - **Hipótese 1:** Considerar apenas os resultados de partidas de temporadas recentes no conjunto de treinamento melhora a previsão.
    - **Hipótese 2:** Criar modelos preditivos separados para cada liga melhora a precisão total da classificação de todas as equipes.

Dataset

- Contém 216.743 partidas de futebol, disputadas em 52 ligas de futebol ao longo de 18 temporadas (de 2000/2001 até 2016/2017).

- O conjunto de teste contém 206 partidas jogadas nas duas primeiras semanas de abril de 2017.

- Originalmente o conjunto tinha 8 features e a classe WDL (Vitória/Empate/Derrota).

Característica	Descrição	Exemplo
Sea	A temporada em que a partida foi jogada	13-14
Lge	O nome da liga	JPN1
Date	A data em que a partida foi jogada	11/05/2013
HT	O nome do time da casa	Kawasaki Frontale
AT	O nome do time visitante	Cerezo Osaka
HS	O número de gols marcados pelo time da casa	2
AS	O número de gols marcados pelo time visitante	2
GD	Diferença de gols: GD=HS−AS	0
WDL	Vitória (W), Empate (D), Derrota (L)	D

Pré-processamento

- O formato da data foi alterado de dd/mm/aaaa para apenas o mês (mm).
- A característica da temporada (ex: 2000/2001) foi convertida para um número inteiro (ex: 1).
- O número de gols marcados por ambas as equipes (HS, AS) foi removido, pois o objetivo era prever apenas o resultado WDL.
- Com isso, por fim, o vetor de características foi reduzido de 8 para 5.

Pré-processamento

Teste de quatro codificações:

1. Dataset original com resultados binários da partida
2. Dataset original com resultados probabilísticos
3. Dataset com pré-processamento e resultados binários
4. **Dataset com pré-processamento e resultados probabilísticos**

Classifier	Original-Binary		Original-Nonzero		Pre-Binary		Pre-Nonzero	
	Accuracy	RSP	Accuracy	RSP	Accuracy	RSP	Accuracy	RSP
Naive Bayes	32.5%	0.374	32.5%	0.249	40.3%	0.422	40.3%	0.234
Decision Tree (J48)	45.1%	0.417	45.1%	0.226	45.1%	0.417	45.1%	0.226

Table IV

A SUMMARY OF EXPERIMENTAL WORK TO EVALUATE THE IMPACT OF THE PRE-PROCESSING STAGE ON THE CLASSIFICATION ACCURACY AND RSP.

Pré-processamento

- Foi criado um novo atributo que representa a porcentagem de vitórias em casa em uma determinada liga.

$$LWS = \frac{Number\ of\ home\text{-}win\ matches\ in\ a\ league}{Total\ number\ of\ matches\ in\ the\ same\ league}$$

Pré-processamento

- Outro atributo foi criado para representar a média das taxas de vitória de um time quando joga em casa, ponderada pelo número de jogos em cada temporada.

$$TWCSH = \sum_{i \in N} W_s \times n_m$$

onde:
TWCSH - Team winning confidence score for home teams;
N - Número de temporadas
W_s - taxa de vitória para o time da casa;
n_m - número de partidas jogadas em cada temporada.

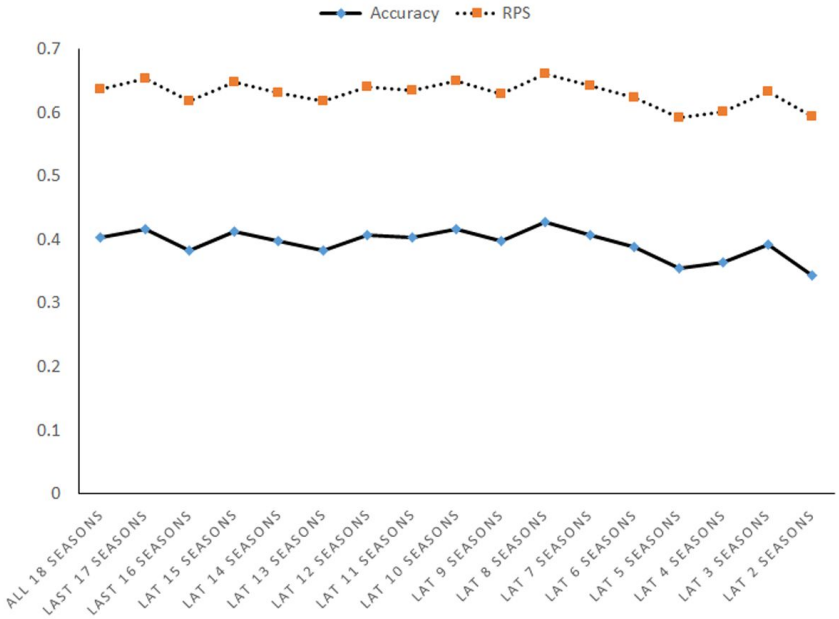
Teste de hipóteses

- **Hipótese 1:** Considerar apenas os resultados de partidas de temporadas recentes no conjunto de treinamento melhora a previsão.

- Jogadores de 15 anos atrás não são os mesmos de hoje.

- Testes com as últimas 18 temporadas, depois com as últimas 17, e decrementando até possuir somente duas.

Teste de hipóteses



Seasons	Prediction Accuracy	RPS
All 18 seasons	0.402912621	0.233826789
Last 17 seasons	0.417475728	0.235538427
Last 16 seasons	0.383495146	0.234563486
Lat 15 seasons	0.412621359	0.235637816
Lat 14 seasons	0.398058252	0.234325155
Lat 13 seasons	0.383495146	0.235356682
Lat 12 seasons	0.40776699	0.232343673
Lat 11 seasons	0.402912621	0.232010002
Lat 10 seasons	0.417475728	0.232200835
Lat 9 seasons	0.398058252	0.232113824
Lat 8 seasons	0.427184466	0.233890627
Lat 7 seasons	0.40776699	0.233965351
Lat 6 seasons	0.388349515	0.235210792
Lat 5 seasons	0.354368932	0.237825716
Lat 4 seasons	0.36407767	0.236592989
Lat 3 seasons	0.393203883	0.239719401
Lat 2 seasons	0.344660194	0.249451525

Teste de hipóteses

- **Hipótese 2:** Criar modelos preditivos separados para cada liga melhora a precisão total da classificação de todas as equipes.

- Não houve melhorias significativas.

- O artigo não entra em detalhes sobre os experimentos e resultados.

Modelos híbridos propostos

Modelos híbridos compostos por um modelo de aprendizado de máquina e um estatístico.

1. Pesos iguais para ambos os modelos
2. Aplica pesos para os modelos e realiza um pós-processamento

Modelo 1

- Este modelo dá pesos iguais às previsões do modelo de aprendizado de máquina e da análise estatística, sem aplicar pós-processamento.

- Para cada partida, as probabilidades de vitória (PW), empate (PD) e derrota (PL) são calculadas como uma média simples.

Modelo 1

$$
\begin{aligned}
PW_{x1} &= \frac{SW_x + MW_x}{2} \\
PD_{x1} &= \frac{SD_x + MD_x}{2} \\
PL_{x1} &= \frac{SL_x + ML_x}{2}
\end{aligned}
$$

onde:

MWx, MDx e MLx - são as probabilidades de vitória, empate e derrota geradas por um classificador Naive Bayes;

SWx, SDx e SLx - são os resultados estatísticos de vitória, empate e derrota para cada dois times jogando uma partida x em todas as temporadas.

Modelo 1

$$SW_x = \frac{\sum_{i \in N} W_x}{\sum_{i \in N} (W_x + D_x + L_x)}$$

$$SD_x = \frac{\sum_{i \in N} D_x}{\sum_{i \in N} (W_x + D_x + L_x)}$$

$$SL_x = \frac{\sum_{i \in N} L_x}{\sum_{i \in N} (W_x + D_x + L_x)}$$

onde:

W_x, D_x e L_x - são o número de vitórias, empates e derrotas para uma partida em uma única temporada;

N - é o número de temporadas.

Modelo 1

Sea	Lge	HT	AT	PW_{x1}	PD_{x1}	PL_{x1}	pWDL-1	RPS-1
18	AUT1	'St Polten'	'Rapid Wien'	0.308214744	0.568155552	0.123629705	D	0.055140316
18	AUT1	'Austria Wien'	'Admira Wacker'	0.679950018	0.157492402	0.16255758	W	0.581820916
18	AUT1	'Sturm Graz'	'Wolfsberger AC'	0.55466103	0.158714875	0.286624096	W	0.140240085
18	AUT1	'SV Mattersburg'	'SV Ried'	0.491084461	0.29917786	0.209737679	W	0.15149246
18	AUT1	'SCR Altach'	'RB Salzburg'	0.320306248	0.316996333	0.36269742	L	0.254375336

Table XIII
PREDICTION RESULTS USING THE FIRST PROPOSED MODEL FOR MATCHES IN THE TEST SET.

Modelo 2

- Este modelo classifica as previsões em níveis "fraco" e "forte" e aplica pós-processamento.

- Uma previsão é considerada forte se:
    - A análise estatística favorece claramente um resultado (ex: a probabilidade estatística de vitória é maior que a de empate e derrota).
    - O modelo de aprendizado de máquina também favorece o mesmo resultado.

Modelo 2

- Condições para uma predição ser considerada forte.

Strong prediction	Condition 1	Condition 2
W_{strong}	$(SW_x > SD_x)$ && $(SW_x > SL_x)$	$(MW_x > MD_x)$ && $(MW_x > ML_x)$
D_{strong}	$(SD_x > SW_x)$ && $(SD_x > SL_x)$	$(MD_x > MW_x)$ && $(MD_x > ML_x)$
L_{strong}	$(SL_x > SW_x)$ && $(SL_x > SD_x)$	$(ML_x > MW_x)$ && $(ML_x > MD_x)$

Table IX

METHOD 2 CONDITIONS TO MEET STRONG PREDICTION LEVELS.

Modelo 2

- **Pós-processamento:**
  - Se uma previsão forte é detectada, o modelo converte a previsão para um resultado binário (ex: se a vitória é forte, Vitória=1, Empate=0, Derrota=0), mostrando alta confiança.
  - Caso contrário, se a previsão não é forte, o modelo calcula a probabilidade usando a mesma média do Modelo 1.

Modelo 2

$$PW_{x2} = \begin{cases} 1 & \text{if } W_{strong} = \text{True} \\ 0 & \text{if } (D_{strong} \parallel L_{strong}) = \text{True} \\ \frac{SW_x + MW_x}{2} & \text{otherwise} \end{cases} \tag{9}$$

$$PD_{x2} = \begin{cases} 1 & \text{if } D_{strong} = \text{True} \\ 0 & \text{if } (W_{strong} \parallel L_{strong}) = \text{True} \\ \frac{SD_x + MD_x}{2} & \text{otherwise} \end{cases} \tag{10}$$

$$PL_{x2} = \begin{cases} 1 & \text{if } L_{strong} = \text{True} \\ 0 & \text{if } (W_{strong} \parallel D_{strong}) = \text{True} \\ \frac{SL_x + ML_x}{2} & \text{otherwise} \end{cases} \tag{11}$$

Modelo 2

- 1ª etapa: Calcula as predições do modelo de ML e o estatístico

Sea	Lge	HT	AT	MW_x	MD_x	ML_x
18	AUT1	'St Polten'	'Rapid Wien'	0.616429488	0.136311103	0.247259409
18	AUT1	'Austria Wien'	'Admira Wacker'	0.751204383	0.0975935	0.151202117
18	AUT1	'Sturm Graz'	'Wolfsberger AC'	0.442655392	0.31742975	0.239914858
18	AUT1	'SV Mattersburg'	'SV Ried'	0.455853133	0.282566246	0.261580621
18	AUT1	'SCR Altach'	'RB Salzburg'	0.458794314	0.270356301	0.270849385

Table X
EXAMPLES OF THE CALCULATIONS OF MW_x, MD_x, AND ML_x FOR MATCHES IN THE TEST SET.

Sea	Lge	HT	AT	SW_x	SD_x	SL_x
18	AUT1	'St Polten'	'Rapid Wien'	0	1	0
18	AUT1	'Austria Wien'	'Admira Wacker'	0.608695652	0.217391304	0.173913043
18	AUT1	'Sturm Graz'	'Wolfsberger AC'	0.666666667	0	0.333333333
18	AUT1	'SV Mattersburg'	'SV Ried'	0.526315789	0.315789474	0.157894737
18	AUT1	'SCR Altach'	'RB Salzburg'	0.181818182	0.363636364	0.454545455

Table XI
EXAMPLES OF THE CALCULATIONS OF SW_x, SD_x, AND SL_x FOR MATCHES IN THE TEST SET.

Modelo 2

- 2ª etapa: Calcula as predições são fortes

Sea	Lge	HT	AT	W_{strong}	D_{strong}	L_{strong}
18	AUT1	'St Polten'	'Rapid Wien'	0	0	0
18	AUT1	'Austria Wien'	'Admira Wacker'	1	0	0
18	AUT1	'Sturm Graz'	'Wolfsberger AC'	1	0	0
18	AUT1	'SV Mattersburg'	'SV Ried'	1	0	0
18	AUT1	'SCR Altach'	'RB Salzburg'	0	0	0

Table XII

EXAMPLES OF THE CALCULATIONS OF W_{strong}, D_{strong}, AND L_{strong} FOR MATCHES IN THE TEST SET.

Modelo 2

- 3ª etapa: Pós processamento final

Sea	Lge	HT	AT	PW_{x2}	PD_{x2}	PL_{x2}	pWDL-2	RPS-2
18	AUT1	'St Polten'	'Rapid Wien'	0.308214744	0.568155552	0.123629705	D	0.055140316
18	AUT1	'Austria Wien'	'Admira Wacker'	1	0	0	W	1
18	AUT1	'Sturm Graz'	'Wolfsberger AC'	1	0	0	W	0
18	AUT1	'SV Mattersburg'	'SV Ried'	1	0	0	W	0
18	AUT1	'SCR Altach'	'RB Salzburg'	0.320306248	0.316996333	0.36269742	L	0.254375336

Table XIV
PREDICTION RESULTS USING THE SECOND PROPOSED MODEL FOR MATCHES IN THE TEST SET.

Comparação Final dos Modelos

- Ambos os modelos alcançaram a mesma precisão de 46,6%.
- O modelo 1 obteve um "*Ranked Probability Score (RPS)*" melhor que o modelo 2.

Method	Prediction Accuracy	RPS
1	0.466019417	0.21766467
2	0.466019417	0.264520093

Table XV
A COMPARISON BETWEEN THE ACCURACY AND RSP FOR BOTH PROPOSED METHODS.

Conclusão

- Usar todo o histórico de dados foi mais eficaz do que usar apenas dados recentes;
- Criar modelos separados por liga não aumenta a precisão;
- Codificar os resultados com valores diferentes de zero supera o uso de formato binário.

Referências

H. Elmiligi and S. Saad, "Predicting the Outcome of Soccer Matches Using Machine Learning and Statistical Analysis," 2022 IEEE 12th Annual Computing and Communication Workshop and Conference (CCWC), Las Vegas, NV, USA, 2022, pp. 1-8, doi: 10.1109/CCWC54503.2022.9720896.

Wikipedia.org, “Scoring rule”. Disponível em: <https://en.wikipedia.org/wiki/Scoring_rule>. Acesso em: 9 ago. 2025.