BCC392 - Monografia I

Detecção de *deepfakes* em vídeos

Matheus Peixoto Ribeiro Vieira

Universidade Federal de Ouro Preto, UFOP
Departamento de Computação, DECOM
Orientador: **Pedro Henrique Lopes Silva**



Conteúdo

Introdução

Fundamentação teórica

Desenvolvimento

Resultados

Conclusão

Referências

Introdução

Introdução

- Em 2018, Jordan Peele gravou um vídeo imitando o ex-presidente dos Estados Unidos, Barack Obama.
- O processamento do vídeo gastou 56 horas.



Definição

$$deepfake = Deep\ learning + fake$$

São vídeos que parecem reais, mas alteram rosto, voz, fala ou características das pessoas.



Impactos Reais

- A quantidade de vídeos com *deepfakes* na internet triplicou entre 2022 e 2023 (ŁABUZ; NEHRING, 2024).
- Candidato a presidência da Turquia desiste da eleição após vídeos falsos (KIRBY, 2023).
- Em Hong Kong, uma empresa financeira transferiu U$ 25 milhões após chamada onde todos os presentes eram *deepfakes* (CHEN; MAGRAMO, 2024).

Pergunta de pesquisa

É possível criar um modelo para detecção de *deepfakes* que seja competitivo aos mais avançados, mas que utiliza técnicas que demandem menos poder computacional?

Justificativa

- Os avanços da técnica e tecnologia permitem que cada vez mais pessoas tenham acesso à geração de vídeos falsos.
- O trabalho busca gerar um modelo que seja competitivo e eficiente.

Objetivos

Objetivo geral: Desenvolver um modelo de inteligência artificial baseado em redes neurais para a detecção de *deepfakes* que seja menos custoso, mas com métricas competitivas em relação a outros modelos.

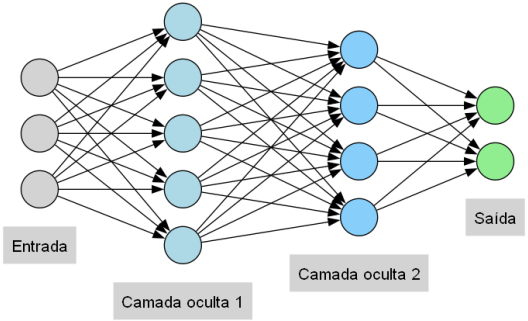
Objetivos específicos:

- Investigar e comparar técnicas recentes de detecção de *deepfakes*
- Avaliar técnicas de pré-processamento de dados
- Implementar um modelo de redes neurais para classificação
- Testar o desempenho do modelo em bases públicas e difundidas na literatura
- Analisar a eficiência do modelo em relação aos da literatura

Fundamentação teórica

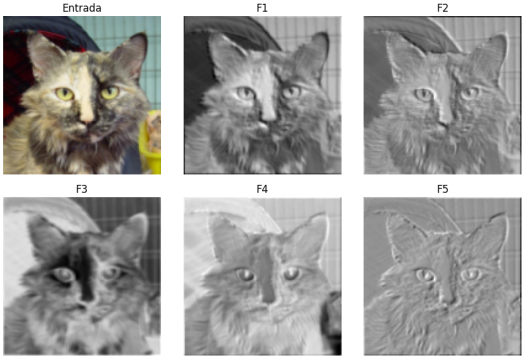
Redes Neurais

- Baseada em neurônios conectados através de camadas por valores conhecidos como pesos e vieses.
- A informação da saída é uma combinação de todos os dados passados anteriormente.



Redes Neurais Convolucionais

- Os pesos estão distribuídos em uma matriz de conhecida como filtro, ou *kernel*, que se desloca pela imagem.
- Também pode estar dividida em camadas



Otimização de hiper-parâmetros

- A definição da quantidade de neurônios, tamanho dos filtros e outros parâmetros é custosa, demorada e por tentativa e erro.
- Há algoritmos que tentam realizar a busca de forma automática
  - **Busca aleatória** em um espaço de possibilidades
  - **Busca em grade** de forma exaustiva
  - **Otimização Bayesiana** com um modelo de Processo Gaussiano e Função de Aquisição

Métricas de avaliação

- Acurácia: $\frac{\text{Vídeos classificados corretamente}}{\text{Total de vídeos}}$
- AUC: Capacidade do modelo de diferenciar classes

Deepfakes

Segundo Heidari et al. (2023), existem quatro grandes categorias de *deepfakes*:

- Troca de expressões
- Geração completa da face
- Manipulação de atributos
- Troca de identidade





Geração de *deepfakes*

Mirsky e Lee (2021) mostram três principais passos:

- Pré-processamento: Localização do rosto, extração de características e mapeamento 3D da imagem 2D
- Geração: Modificação de informação no espaço de características usando GANs
- Pós-processamento: Mesclagem do novo rosto corrigindo texturas, iluminação e ruídos.

Trabalhos relacionados

- Hernandez-Ortega et al. (2022) trabalha com a hipótese de que modelos que geram *deepfakes* não preservam sinais fisiológicos.
- Adaptam um modelo que identifica batimentos cardíacos para detectar a presença de *deepfake*.
- **Resultados na Celeb-DF v2:**
  - 98,7% de acurácia no nível de quadros;
  - 99,47% com janela temporal de 7s (média ou mediana);
  - 100% de acurácia com 6s quando se conhece previamente a distribuição real/falsa.

Trabalhos relacionados

- Khormali e Yuan (2021) extrai as faces de 20% dos quadros com o RetinaFace.
- Extrai *features* com CNN e combina com mapas de atenção.
- Técnicas de atenção de Face Close-UP e Face-Shut OFF
- **Resultados de AUC com a Celeb-DF v2:**
  - ResNet: 0.9865
  - Xception: 0.9784
  - VGG: 0.9801
  - MobileNet: 0.9476

Trabalhos relacionados

Trabalho	Modalidade	Tempo	Dataset	Acurácia	AUC
Khan e Alam (2022)	Imagens	Nível de imagem	140k Real and Fake Faces	99,68%	
Hernandez-Ortega et al. (2022)	Vídeo	7 segundos	Celeb-DF v2	99,47%	0.9999
Masud et al. (2023)	Vídeo	20 quadros	Celeb-DF	99,24%	
Ganguly et al. (2022)	Vídeo	Nível de imagem	FaceForensics++	97,00%	
Reis e Ribeiro (2024)	Vídeo	500 quadros	Celeb-DF v2	97,50%	0.9940
Khormali e Yuan (2021)	Vídeo	20%	Celeb-DF v2		0.9865
Yermakov, Cech e Matas (2025)	Vídeo	32 quadros	Celeb-DF v2 DFDC DFD		0.9662 0.8715 0.9800
Heo, Yeo e Kim (2023)	Vídeo	Não informado	Celeb-DF v2 DFDC		0.9930 0.9780
Chen et al. (2021)	Vídeo	7 quadros	UADFV Celeb-DF Celeb-DF v2		1.0000 0.9495 0.9056
Hamza et al. (2022)	Áudio	Não informado	Fake-or-Real	93,00%	
Shahzad et al. (2023)	Áudio/Vídeo	Não informado	FakeAVCeleb	99,00%	

Desenvolvimento

Base de dados

- Celeb-DF v2 (LI et al., 2020) possui 890 vídeos reais e 5.639 vídeos falsos.
- Os vídeos possuem variedades de contextos e grupo étnicos

Figura: Imagem do conjunto *Celeb Real*, *Youtube Real* e *Celeb Synthesis*, respectivamente







Base de dados

Tabela: Informações da quantidade de quadros dos vídeos

Conjunto de dados	Média	Desvio padrão	Mínimo	Mediana	Máximo
Completo	379,2	84,7	105	379,2	740
Falsos	375,4	83,8	105	375,4	740
Reais	403,6	86,6	126	403,6	740

Pré-processamento

- Uso de 24 quadros para cada vídeo
- Separação dos dados de teste proposto pelos autores: 178 vídeos reais e 340 vídeos falsos
- Para treinamento: 712 vídeos reais e 5.299 vídeos falsos
- Extração de múltiplas sequências dos vídeos reais para equilibrar o dataset

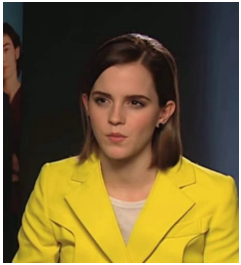
Tabela: Divisão dos vídeos.

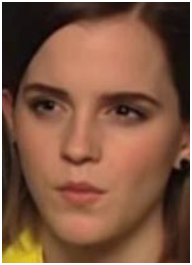
	Real	Falso	Total
Treinamento	$548 \times 9 = 4.932$	4.973	9.905
Validação	$163 \times 2 = 326$	326	652
Teste	178	340	518
Total	5.436	5.639	11.075

Extração de faces

- Uso do RetinaFace para extrair as faces
- Redimensionamento para uma imagem de 299×299 para alimentar o modelo
- Foco em manter o *aspect-ratio* e evitar distorções

Extração de faces







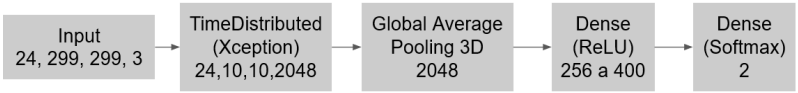
Extração de faces





Modelo proposto

- Modelo baseado em Xception, utilizada em Ganguly et al. (2022) e Khormali e Yuan (2021), com otimizador SGD.
- Otimização de hiper-parâmetros:
  - Camada densa: Entre 256 a 400 com incremento de 16
  - Taxa de aprendizado: Entre 1×10^{-4} e 1×10^{-2} de forma logarítmica
  - *Momentum*: Entre 0,87 e 0,92 amostrado de forma logarítmica
  - *Nesterov*: *Booleano*



Resultados

Modelo obtido

- Número de neurônios da camada densa: 304;
- Taxa de aprendizado: 7.1030×10^{-4};
- *Momentum*: 0.9144;
- Nesterov: `Falso`.

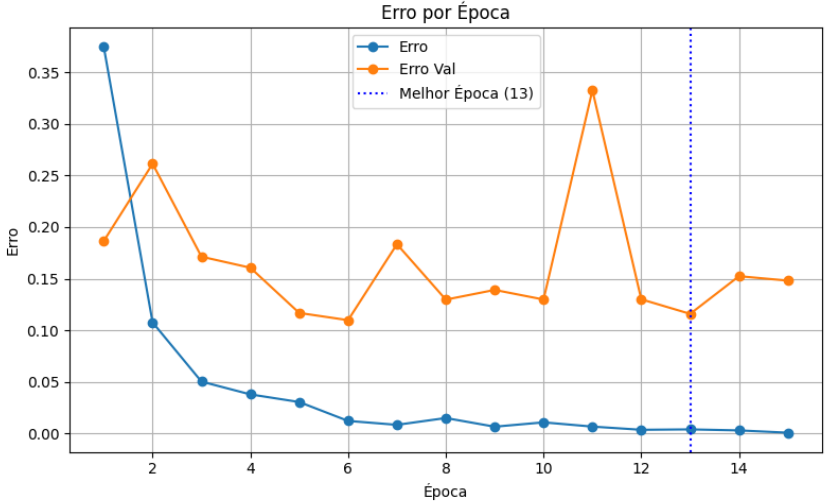


Treinamento

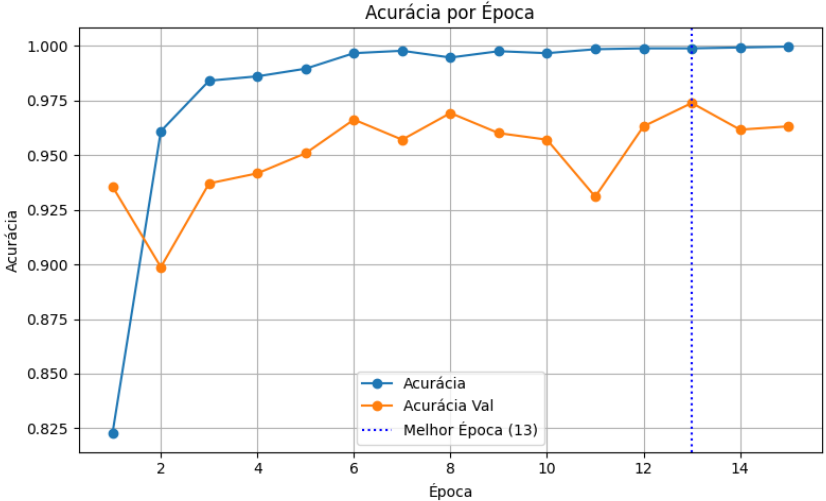
Tabela: Resultados obtidos durante as 15 épocas de treinamento.

Época	Erro	Acurácia	AUC	Erro Val	Acurácia Val	AUC Val
1	0.3748	0.8230	0.9120	0.1864	0.9356	0.9799
2	0.1076	0.9610	0.9921	0.2613	0.8988	0.9662
3	0.0503	0.9841	0.9981	0.1713	0.9371	0.9849
4	0.0379	0.9861	0.9990	0.1606	0.9417	0.9845
5	0.0305	0.9896	0.9989	0.1168	0.9509	0.9917
6	0.0122	0.9967	0.9995	0.1098	0.9663	0.9931
7	0.0084	0.9978	0.9999	0.1834	0.9571	0.9826
8	0.0150	0.9947	0.9997	0.1297	0.9693	0.9894
9	0.0066	0.9976	0.9999	0.1391	0.9601	0.9885
10	0.0108	0.9967	0.9995	0.1298	0.9571	0.9884
11	0.0067	0.9985	0.9999	0.3325	0.9310	0.9640
12	0.0036	0.9989	0.9999	0.1300	0.9632	0.9897
13	0.0040	0.9989	1.0000	**0.1159**	**0.9739**	**0.9876**
14	0.0030	0.9993	0.9999	0.1524	0.9617	0.9846
15	**0.0008**	**0.9997**	**1.0000**	0.1481	0.9632	0.9867

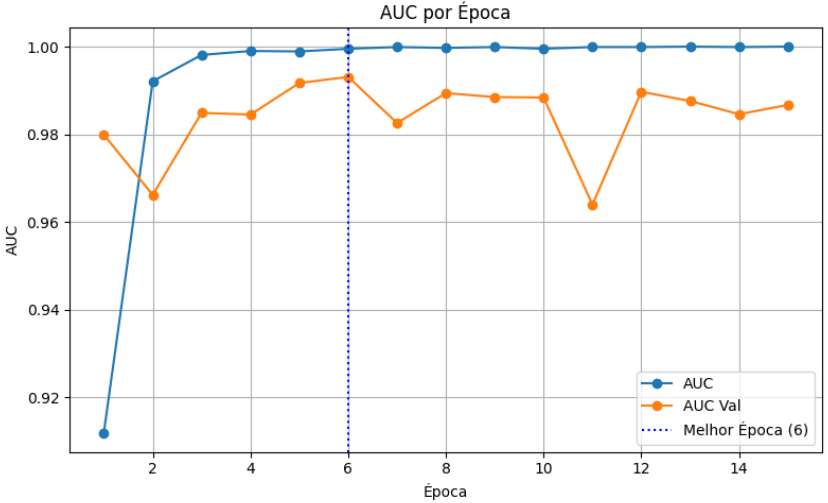
Treinamento - Erro



Treinamento - Acurácia



Treinamento - AUC



Resultados

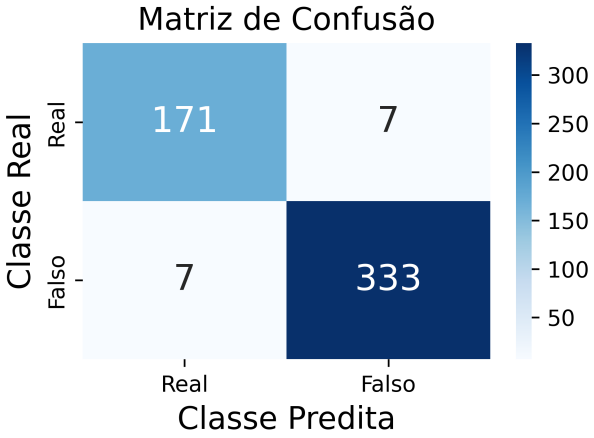
	Erro	Acurácia	AUC
Validação	0.1159	97,39%	0.9876
Teste	0.0789	97,30%	0.9957

Resultados

Tabela: Comparação do modelo proposto com trabalhos que utilizaram a Celeb-DF v2, ordenados pelo AUC

Trabalho	Quadros usados	Acurácia	AUC
Chen et al. (2021)	7	Não informado	0.906
Yermakov, Cech e Matas (2025)	32	Não informado	0.966
Khormali e Yuan (2021)	Não informado	Não informado	0.987
Heo, Yeo e Kim (2023)	32	Não informado	0.9930
Reis e Ribeiro (2024)	50 + 50*9	97,50%	0.994
Modelo proposto	24	97,30%	0.9957
Hernandez-Ortega et al. (2022)	210	99,47%	0.9999

Matriz de Confusão



Análise de predições

Vídeos reais classificados como falsos

- Alguns vídeos foram redimensionados para atingir o limite de 299×299
- Em outros casos, a imagem era muito pequena



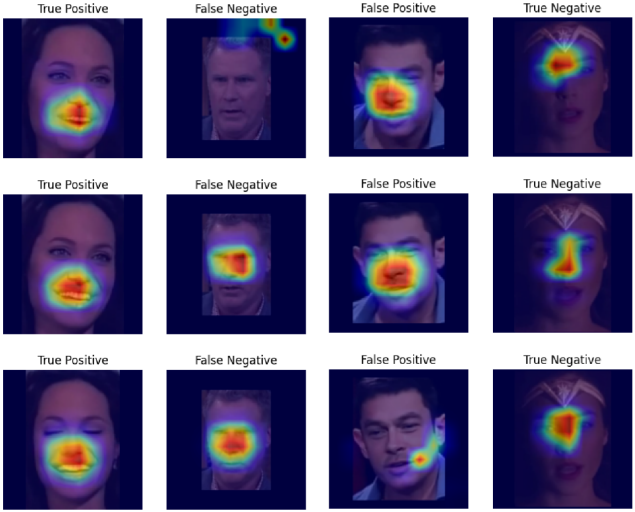
Análise de predições

Vídeos falsos classificados como reais

- Todos os vídeos eram menores que 299×299
- Artefatos podem não ter sido captados



Mapa de ativação



Conclusão

Conclusão

- A literatura foi devidamente explorada para encontrar modelos de CNN promissores e técnicas de pré-processamento.
- Mostrada a qualidade da otimização de hiper-parâmetros.
- Foi desenvolvido um modelo com resultados competitivos com a literatura, com AUC de 0.9957 e acurácia de 97,30%.
- O modelo obtido apresenta uma quantidade de dados necessários menor do que modelos com resultados próximos.
- Foi possível atingir os objetivos propostos e são abertos espaços para desenvolvimentos futuros.

Trabalhos futuros

Próximos passos para o desenvolvimento da Monografia II:

Atividades	Semanas
Construção e avaliação de diferentes redes de classificação	01-05
Aprimoramento da rede proposta	06-10
Validação do modelo proposto	11-14
Refatoração e disponibilização do código fonte	15-16
Escrita da Monografia	05-16
Apresentação da Monografia	17

Referências

Referências I

CHEN, H.; MAGRAMO, K. *Finance worker pays out $25 million after video call with deepfake chief financial officer*. 2024. Disponível em: <https://edition.cnn.com/2024/02/04/asia/deepfake-cfo-scam-hong-kong-intl-hnk/index.html>.

CHEN, H.-S.; ROUHSEDAGHAT, M.; GHANI, H.; HU, S.; YOU, S.; KUO, C. C. J. *DefakeHop: A Light-Weight High-Performance Deepfake Detector*. 2021. Disponível em: <https://arxiv.org/abs/2103.06929>.

GANGULY, S.; GANGULY, A.; MOHIUDDIN, S.; MALAKAR, S.; SARKAR, R. Vixnet: Vision transformer with xception network for deepfakes based video and image forgery detection. *Expert Systems with Applications*, v. 210, p. 118423, 2022. ISSN 0957-4174. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0957417422015251>.

HAMZA; AMEER; JAVED; REHMAN, A. R.; IQBAL; FARKHUND; KRYVINSKA; NATALIA; ALMADHOR; S., A.; JALIL; ZUNERA; BORGHOL; ROUBA. Deepfake audio detection via mfcc features using machine learning. *IEEE Access*, v. 10, p. 134018–134028, 2022.

HEIDARI, A.; NAVIMIPOUR, N.; DAG, H.; UNAL, M. Deepfake detection using deep learning methods: A systematic and comprehensive review. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, v. 14, 11 2023.

HEO, Y.-J.; YEO, W.-H.; KIM, B.-G. Deepfake detection algorithm based on improved vision transformer. *Applied Intelligence*, v. 53, n. 7, p. 7512–7527, Apr 2023. ISSN 1573-7497. Disponível em: <https://doi.org/10.1007/s10489-022-03867-9>.

Referências II

HERNANDEZ-ORTEGA, J.; TOLOSANA, R.; FIERREZ, J.; MORALES, A. Deepfakes detection based on heart rate estimation: Single- and multi-frame. In: _____. *Handbook of Digital Face Manipulation and Detection: From DeepFakes to Morphing Attacks*. Cham: Springer International Publishing, 2022. p. 255–273. Disponível em: <https://doi.org/10.1007/978-3-030-87664-7_12>.

KHAN, M.; ALAM, K. N. Detecting deepfake images using deep learning techniques and explainable ai methods. *Intelligent Automation and Soft Computing*, v. 35, 07 2022.

KHORMALI, A.; YUAN, J.-S. Add: Attention-based deepfake detection approach. *Big Data and Cognitive Computing*, v. 5, n. 4, 2021. ISSN 2504-2289. Disponível em: <https://www.mdpi.com/2504-2289/5/4/49>.

KIRBY, P. *Muharrem Ince: Turkish candidate dramatically pulls out before election*. BBC News, 2023. Disponível em: <https://www.bbc.com/news/world-europe-65560052>.

LI, Y.; YANG, X.; SUN, P.; QI, H.; LYU, S. Celeb-df: A large-scale challenging dataset for deepfake forensics. In: *IEEE Conference on Computer Vision and Patten Recognition (CVPR)*. [S.l.: s.n.], 2020.

MASUD, U.; SADIQ, M.; MASOOD, S.; AHMAD, M.; EL-LATIF, A. A. A. Lw-deepfakenet: a lightweight time distributed cnn-lstm network for real-time deepfake video detection. *Signal, Image and Video Processing*, v. 17, n. 8, p. 4029–4037, Nov 2023. ISSN 1863-1711. Disponível em: <https://doi.org/10.1007/s11760-023-02633-9>.

Referências III


MIRSKY, Y.; LEE, W. The creation and detection of deepfakes: A survey. *ACM Computing Surveys*, Association for Computing Machinery (ACM), v. 54, n. 1, p. 1–41, jan. 2021. ISSN 1557-7341. Disponível em: <http://dx.doi.org/10.1145/3425780>.


REIS, P. M. G. I.; RIBEIRO, R. O. A forensic evaluation method for deepfake detection using dcnn-based facial similarity scores. *Forensic Science International*, v. 358, p. 111747, 2024. ISSN 0379-0738. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0379073823001974>.


SHAHZAD, S. A.; HASHMI, A.; PENG, Y.-T.; TSAO, Y.; WANG, H.-M. *AV-Lip-Sync+: Leveraging AV-HuBERT to Exploit Multimodal Inconsistency for Video Deepfake Detection*. 2023. Disponível em: <https://arxiv.org/abs/2311.02733>.


YERMAKOV, A.; CECH, J.; MATAS, J. *Unlocking the Hidden Potential of CLIP in Generalizable Deepfake Detection*. 2025. Disponível em: <https://arxiv.org/abs/2503.19683>.


ŁABUZ, M.; NEHRING, C. On the way to deep fake democracy? deep fakes in election campaigns in 2023. *European Political Science*, Apr 2024. ISSN 1682-0983. Disponível em: <https://doi.org/10.1057/s41304-024-00482-9>.

Muito obrigado pela atenção.
Dúvidas?