UNIVERSIDADE FEDERAL DE OURO PRETO
DEPARTAMENTO DE CIÊNCIA DE COMPUTAÇÃO
PROCESSAMENTO DIGITAL DE IMAGENS

Projeto de Pesquisa

DETECÇÃO DE DEEPFAKES

Alunos:

Felipe Braz Marques,

Matheus Peixoto Ribeiro Vieira,

Nicolas Expedito Lana Mendes,

Vitor Oliveira Diniz

Resumo

Este trabalho investiga a detecção de *deepfakes*, mídias falsas geradas por técnicas de inteligência artificial capazes de manipular rostos e expressões de forma altamente convincente, representando riscos significativos em contextos como fraudes e desinformação. Foi proposta uma abordagem baseada na arquitetura Xception adaptada com camadas *TimeDistributed* e *GlobalAveragePooling3D*, utilizando apenas 24 quadros de cada vídeo da base Celeb-DF v2, de forma a reduzir o custo computacional sem comprometer o desempenho. O processo incluiu pré-processamento com extração de faces via RetinaFace, balanceamento do conjunto de dados por aumento de segmentos em vídeos reais e ajuste de hiper-parâmetros com KerasTuner. O modelo alcançou acurácia de 97,30% e AUC de 0,9957 no conjunto de teste, resultados competitivos frente à literatura, mesmo empregando menos dados.

1 Introdução

O termo *deepfake* é uma combinação dos termos "*deep learning*" e "*fake*", e refere-se a uma tecnologia que utiliza redes neurais profundas para gerar arquivos de mídia altamente convincentes e realistas, sendo utilizado para a manipulação de rostos e vozes, gerando fotos, vídeos e arquivos de áudio (Mirsky & Lee, 2021).

Em Hong Kong, uma multinacional do setor financeiro transferiu cerca de 25 milhões de dólares para golpistas depois que um dos funcionários da empresa recebeu um e-mail do chefe financeiro da sede e participou de uma videoconferência com ele e outros colaboradores. No entanto, todos os participantes da reunião pareciam e soavam como as pessoas reais, mas eram *deepfakes* (H. Chen & Magramo, 2024).

Segundo Heidari et al. (2023), as manipulações faciais por meio de deepfakes ocorrem por troca de expressões (modificando uma expressão de tristeza para uma de felicidade, por exemplo), geração completa da face (onde o rosto do indivíduo é completamente gerado artificialmente), manipulação de atributos (Mudanças no formato da cor do cabelo, olhos, pele, etc) e troca de identidade (A face de uma pessoa origem é substituída pela de uma pessoa alvo).

Nesse contexto, ao analisar diferentes abordagens de pesquisa sobre o tema, Heidari et al. (2023) observaram que a maior parte dos esforços concentra-se na detecção de *deepfakes* em vídeos, seguida pela análise de conteúdos multimídia e, por último, de arquivos exclusivamente em áudio. Consequentemente, as redes neurais convolucionais se tornam a estratégia mais explorada, uma vez que a maioria das pesquisas baseiam-se no uso de imagens.

Logo, visando diferenciar conteúdos falsos daqueles verdadeiros, pesquisas sobre métodos de classificação foram feitas, utilizando, principalmente, CNN, como evidenciado por Heidari et al. (2023). Trabalhos como o de Masud et al. (2023) utilizam CNN pré-treinadas para que aprendam as características do que é real e falso para ajudar na decisão final. Outros estudos propõem hipóteses menos tradicionais, como ocorre em Hernandez-Ortega et al. (2022), que utiliza um modelo base para extrair os batimentos cardíacos com base em aspectos fisiológicos.

Assim, esse trabalho busca explorar o uso de Redes Convolucionais para classificar vídeos como reais ou falsos. Como resultado, foi possível a construção de um modelo de redes neurais baseado na rede convolucional Xception que atingiu uma acurácia de 97,30% e um AUC de 0.9957

para a base de dados Celeb-DF v2, utilizando somente 24 quadros dos vídeos da mesma.

2 Estado da Arte

Com o objetivo de identificar inconsistências na movimentação dos pixeis faciais, características comuns em vídeos manipulados por deepfake, o estudo de Saikia et al. (2022) propõe a extração do campo de fluxo óptico (optical flow field) a partir de pares consecutivos de quadros contendo apenas o rosto. Os dados foram coletados das bases Celeb-DF, DeepFake Detection Challenge (DFDC) e FaceForensics++.

O campo de fluxo óptico serve como entrada para uma rede neural convolucional (CNN), responsável por extrair características que são então processadas por duas camadas LSTM com dropout de 0,5. A classificação final é feita com função softmax e perda por entropia cruzada (cross-entropy loss). Dentre diferentes modelos testados, a ResNet50 obteve o melhor desempenho como base da CNN.

O treinamento foi realizado com vídeos contendo entre 10 e 100 quadros, em incrementos de 10. Observou-se uma correlação positiva entre o número de quadros e a acurácia do modelo. Para o DFDC, a melhor acurácia (66,26%) foi alcançada com 30 quadros. Já na FaceForensics++, a máxima acurácia (91,21%) ocorreu com 70 quadros, e na Celeb-DF, 79,49% com 90 quadros.

O estudo justifica bem a escolha dos modelos utilizados e apresenta uma metodologia sólida, principalmente na escolha do uso da ResNet50, escolhida após diversas rodadas de treinamento. No entanto, uma limitação importante é a não adoção da divisão de dados sugerida pelos autores da Celeb-DF, o que dificulta comparações diretas com outros trabalhos e pode introduzir viés na seleção dos vídeos.

O trabalho de Khan & Alam (2022) foca na detecção de *deepfakes* em imagens estáticas, utilizando o conjunto de dados "140k Real and Fake Faces"e explorando diferentes modelos de CNNs para as predições. Foram avaliadas as arquiteturas InceptionResNetV2, DenseNet201, ResNet152V2 e InceptionV3, todas conectadas a uma camada *GlobalAveragePooling* para a linearização das características extraídas. Em seguida, essas são passadas para uma camada densa com 512 neurônios e ativação ReLU, e por fim, para uma camada densa com dois neurônios e ativação *softmax* para a classificação.

Todos os modelos foram treinados sob as mesmas condições: divisão de dados, taxa de aprendizagem e número de épocas. A InceptionResNetV2 apresentou o melhor desempenho, alcançando 99,86% de acurácia nos testes, superando os demais modelos e resultados encontrados na literatura.

Além disso, o artigo incorpora a abordagem de *Explainable AI* com o uso do *framework* LIME, permitindo interpretar visualmente quais regiões da imagem influenciaram a decisão do modelo. Embora não contribua para o aumento da acurácia, essa explicabilidade aumenta a confiança no sistema por parte dos usuários.

A proposta é clara e facilmente replicável, mas sua aplicação restrita a imagens limita sua utilidade prática, dado o crescente uso de *deepfakes* em vídeos. Trabalhos futuros poderiam explorar a integração do LIME em contextos dinâmicos para explicar predições em sequência de quadros.

Visando capturar características espaço-temporais em vídeos da Celeb-DF, de Lima et al. (2020) explora diversas arquiteturas de redes neurais convolucionais adaptadas para lidar com a dimensão temporal.

A primeira abordagem é uma RCN, composta por uma CNN (VGG11), seguida de uma camada LSTM e uma camada densa com 2 neurônios para classificação. Utilizando apenas 10 quadros por vídeo, essa configuração atingiu uma acurácia de 76,25

A arquitetura I3D (Inflated 3D ConvNet) transforma filtros 2D em 3D, reaproveitando modelos previamente treinados. Com base na Inception-V1, essa abordagem alcançou 92,28% de acurácia.

Já as CNNs 3D, que combinam convoluções e *pooling* em três dimensões com conexões residuais, utilizaram 16 quadros e obtiveram 98,26% de acurácia.

A MC3, semelhante às CNNs 3D, emprega convoluções 3D nas primeiras camadas e convoluções 2D a partir da terceira. Também com 16 quadros, alcançou 97,49% de acurácia.

Por fim, a ResNet (2+1)D decompõe as convoluções 3D em uma convolução 2D (espacial) seguida de uma 1D (temporal), o que aumenta a não linearidade e a capacidade de aprendizagem do modelo. Essa arquitetura atingiu uma acurácia de 98,07

O estudo apresenta uma metodologia robusta e compara eficazmente diferentes abordagens para análise de vídeos com poucos quadros, o que favorece a eficiência computacional. No entanto, há limitações: nem todos os modelos indicam claramente o número de quadros utilizados, e há variações entre eles, o que pode enviesar os resultados, especialmente considerando a correlação entre quantidade de quadros e acurácia. Ademais, o artigo não adota as divisões padrão de treino e

teste propostas pelos autores da base Celeb-DF, dificultando a comparação com outros trabalhos.

Vídeos com manipulações faciais não reproduzem corretamente as características fisiológicas dos seres humanos, logo, um modelo capaz de estimar a frequência cardíaca com base nas imagens faciais teria dificuldades em realizar boas predições. Seguindo essa hipótese, Hernandez-Ortega et al. (2022) propuseram o modelo *DeepFakesON-Phys*, que adapta a arquitetura do modelo de predição de batimentos cardíacos *DeepPhys*.

O modelo proposto é dividido em duas ramificações, e cada uma delas receberá um frame normalizado de acordo com o seu objetivo. A primeira ramificação é a *Motion Model*, que visa identificar mudanças em quadros consecutivos. Para atingir esse objetivo, inicialmente ocorre a subtração do quadro atual t com o quadro anterior $t-1$. Em seguida essa modificação é passada por camadas convolucionais e de *pooling*, aplicando o produto de Hadamard de algumas camadas com informações vindas da segunda ramificação, a *Appereance Model*, que recebe um único quadro normalizado e, por meio de convoluções e *poolings* tenta extrair características dos locais com informações mais relevantes para detectar *deepfakes*. Por fim, com os dados agrupados, eles são passados para uma camada densa para a realização da classificação binária com *sigmoid*.

O modelo foi avaliado em duas bases de dados diferentes, a *Celeb-DF v2* e a *DFDC Preview*. Ademais, duas abordagens foram avaliadas, a primeira foi uma avaliação no nível de quadros, que obteve uma acurácia de 98,7% e 94,4% para as respectivas bases de dados.

Em seguida, foi adicionada uma janela temporal que combina as predições do modelo em diferentes espaços de tempo, gerando um resultado final a partir da média das previsões, da mediana e por QCD (*Quickest Change Detection*). Como resultado, com sete segundos de vídeo foi possível obter uma acurácia de 99,47% e um AUC de 99,99% para a média e mediana no conjunto da Celeb-DF v2. Por outro lado, o QCD obteve 100% de acurácia e AUC com seis segundos de vídeo.

Entre os principais pontos do artigo está um modelo inovador e diferente dos demais, utilizando uma hipótese ousada e que, no final, foi válida e muito eficaz. Todavia o tempo de seis e sete segundos utilizados na janela temporal aumenta consideravelmente o custo de processamento de um clipe, dificultando a aplicação de tal modelo. Ademais, muitos vídeos da base de dados Celeb-DF não possuem tal duração, e não é mencionado o que é feito em relação a esses vídeos. Por fim, é necessário ressaltar que o QCD necessita de conhecimentos a priori a respeito das distribuições dos dados, o que pode não ser viável em contextos reais.

O trabalho de Masud et al. (2023) aborda o problema de desbalanceamento da base Celeb-DF, que possui aproximadamente 10× mais vídeos falsos do que reais. Para mitigar esse desequilíbrio, os autores propõem a criação de vídeos artificiais de 15 segundos, compostos por trechos de 3 segundos selecionados aleatoriamente dos vídeos originais. A partir desse novo conjunto, a divisão dos dados foi realizada em proporção 80:20 para treino e teste.

De cada vídeo gerado, 20 quadros foram uniformemente amostrados e utilizados como entrada para o modelo proposto. A arquitetura consiste em uma VGG16 pré-treinada para extração de características espaciais, envolta por uma camada *TimeDistributed*, que aplica os mesmos pesos a todos os quadros. Após a extração, as representações passam por uma camada de *global average pooling* e são processadas por uma LSTM com 128 unidades, seguida por uma camada densa com 256 neurônios (ativação ReLU) e, por fim, uma saída sigmoide para a classificação binária.

O modelo obteve resultados expressivos, com acurácia de 99,24% e AUC de 99,52, destacando-se pela alta performance aliada a um baixo custo computacional, sendo até 152 vezes mais leve que modelos concorrentes.

Contudo, o estudo apresenta uma limitação metodológica relevante: não há clareza quanto à garantia de que trechos de vídeo utilizados na composição dos conjuntos de treino e teste são mutuamente exclusivos. Caso haja interseção, mesmo parcial, entre os dados de ambos os conjuntos, o modelo pode sofrer de vazamento de dados, comprometendo a validade dos resultados ao favorecer a memorização em detrimento da generalização.

Reis & Ribeiro (2024) propõem uma abordagem onde deseja-se verificar a veracidade de um vídeo onde já se conhece a identidade da pessoa retratada e possui arquivos de mídia reais da mesma. Dessa forma, 50 quadros são extraídos do vídeo questionado e mais 50 quadros são extraídos de 9 a 11 vídeos autênticos. Em seguida, essas informações são passadas para uma rede ResNet100 treinada sobre o *dataset* MS1Mv2.

Dentre todos as imagens apresentadas no modelo, são feitas diferentes combinações entre elas a fim de se calcular a similaridade entre os rostos questionados e os reais. Com isso, 25 mil pontuações são geradas, e a maior delas é utilizado em um classificador binário que decidirá a veracidade do conteúdo.

A metodologia apresentada é simples de ser entendida e gera bons resultados, como pode ser observado na base de dados Celeb-DF-V2, onde foi obtido um AUC de 0.994 e uma acurácia de

97,5%.

Por outro lado, o principal ponto negativo da abordagem apresentada é a necessidade de uma grande quantidade de vídeos reais para que se possa utilizar o método, o que acaba se tornando inviável para ataques a pessoas comuns.

Utilizando sistemas de atenção, Khormali & Yuan (2021) propõem um modelo dividido em três componentes principais, a localização da face e o pré-processamento, onde as faces de 20% dos quadros são extraídas utilizando o *RetinaFace*; aplicação de uma rede convolucional para a extração de *feature maps*, combinando-as com mapas de atenção por multiplicação ponto a ponto & *data augmentation* baseado em atenção, aplicando duas técnicas, a primeira, chamada de Face Close-UP, um mapa de atenção escolhe uma região do rosto que parece ser mais importante e a extrai, gerando uma imagem somente com essa área, já a outra, chamada de Face Shut-Off, oculta essas regiões consideradas mais importantes. Assim, uma técnica aprofunda a análise local, enquanto a outra incentiva a análise de outras partes.

Dessa forma, para a base de dados Celeb-DF v2, o modelo atingiu AUC de 0.9865 com a ResNet, 0.9784 com a Xception, 0.9801 com a VGG e 0.9476 com a MobileNet.

A metodologia proposta apresenta uma forma não ortodoxa para a realização de *data augmentation* que pode gerar mais desafios para o modelo, melhorando a sua generalização, ademais é importante notar como o uso dos mapas de atenção é agnóstico em relação ao modelo de CNN usado como *backbone*, permitindo novos testes.

Contudo essa característica do modelo leva a um dos seus pontos negativos que é um maior custo computacional, uma vez que utiliza duas técnicas diferentes para extrair informações, e que variam muito de acordo com a CNN escolhida.

O CLIP é um modelo que recebe uma imagem como entrada e produz um texto descrevendo o que está sendo exibido. Ele utiliza em seu backbone o encoder CLIP ViT-L/14, que consegue generalizar bem para diferentes *datasets*. Utilizando-o, Yermakov et al. (2025) congela todos os seus pesos durante o treinamento e utiliza seus tokens de classificação para um classificador binário decidir se o vídeo é real ou apresenta *deepfake* a partir de 32 quadros do vídeo.

O modelo foi treinado na base de dados FaceForensics++ e foi avaliado em diferentes outros *datasets*, como a Celeb-DF v2, onde fora utilizada a separação oficial dos dados de avaliação, onde atingiu AUC de 0.9662, a DFDC que teve AUC de 0.8715 e a DFD que teve AUC de 0.980.

O trabalho apresenta uma boa generalização dos resultados, utilizando muito bem o CLIP e evitando um treinamento extensivo nele, o que facilita a reprodutibilidade da pesquisa. Por outro lado, o CLIP ainda é um modelo muito grande e custoso, o que dificulta o seu uso. Ademais, o modelo leva em consideração somente imagens estáticas, ignorando uma das principais características dos vídeos, que são as mudanças temporais.

Utilizando tanto redes convolucionais quanto Vision Transformers, Heo et al. (2023) propõem um modelo que, a partir de rostos extraídos com MTCNN, utiliza uma EfficientNet-B7 para extrair características locais das imagens e um ViT para capturar informações globais, concatenando ambas as saídas e processando-as por camadas de atenção. Durante o treinamento, o modelo é otimizado por destilação a partir de um professor baseado na EfficientNet-B7, utilizando um *token* de classe com os rótulos verdadeiros e um *token* de destilação com as predições do professor.

Dessa forma, foi possível obter um AUC de 0.978 no *dataset* DFDC e de 0.993 no Celeb-DF v2.

Assim, o modelo se destaca por unir características de redes convolucionais e vision transformers, ao mesmo tempo que utiliza destilação para prevenir overfitting. Todavia, isso o leva ao seu principal ponto negativo, que é o custo computacional: ViTs já são naturalmente custosos, e seu uso em conjunto com redes convolucionais pode se tornar inviável em cenários com recursos limitados.

Explorando técnicas que não envolvem redes neurais, H.-S. Chen et al. (2021) propõem um modelo baseado em Successive Subspace Learning. Inicialmente, são extraídas as regiões do olho esquerdo, olho direito e boca de sete quadros por vídeo. As imagens são processadas pelo módulo PixelHop++, que extrai características espectrais e espaciais locais. Em seguida, essas características são reduzidas por PCA e passadas para classificadores XGBoost individuais por canal. A decisão final é obtida por meio de um ensemble que combina as saídas das diferentes regiões e quadros.

Como resultado, foi possível obter um AUC de 1.00 na base de dados UADFV, 0.9495 na Celeb-DF v1 e 0.9056 na Celeb-DF v2.

Mesmo o resultado sendo inferior a de outros trabalhos, ainda assim apresenta uma boa diferenciação de classes, principalmente por se tratar de um modelo com cerca de 43 mil parâmetros, sendo extremamente mais rápido do que modelos simples que utilizam redes neurais e uma maior

quantidade de quadros.

Por outro lado, o modelo não explora as características temporais dos vídeos, ficando preso somente nas análises das imagens.

Artigo	*Dataset* utilizado	Nº frames	Acurácia	AUC
Saikia et al. (2022)	DFDC FaceForensics++ Celeb-DF	30 70 90	66,26% 91,21% 74,49%	
Khan & Alam (2022)	140k Real and Fake Faces	Imagem	99,86%	
de Lima et al. (2020)	Celeb-DF	10 Não informado 16 16 Não informado	RCN: 76,25% I3D: 92,28% 3D CNN: 98,26% MC3: 97,49% ResNet(2+1)D: 98,07%	
Hernandez-Ortega et al. (2022)	DFDC Preview Celeb-DF v2	Análise de quadro 180	94,4% 99,47%	 0.9999
Masud et al. (2023)	Celeb-DF	20	99,24%	
Reis & Ribeiro (2024)	Celeb-DF v2	500 quadros	97,50%	0.994
Khormali & Yuan (2021)	Celeb-DF v2	20%		0.9865
Yermakov et al. (2025)	DFDC DFD Celeb-DF v2	32		0.8715 0.980 0.993
Heo et al. (2023)	Celeb-DF v2 DFDC	Não informado		0.993 0.978
H.-S. Chen et al. (2021)	UADFV Celeb-DF Celeb-DF v2	7		1.00 0.9495 0.9056

Tabela 1: Resumo dos artigos relacionados

A tabela 1 resume os melhores resultados obtidos pelos diferentes estudos, bem como as bases utilizadas. Dessa forma, mesmo com *datasets* diferentes e formas não iguais da separação de dados entre treino e teste, percebe-se a grande capacidade dos modelos em realizar a generalização entre os dados reais e os dados falsos, sendo evidenciado pela acurácia dos modelos. Todavia, essa métrica analisada de forma superficial pode ser enganosa, uma vez que muitas bases possuem um grande desbalanceamento da quantidade de vídeos reais e aqueles com *deepfakes*.

3 Metodologia

3.1 Dataset

O conjunto de dados a ser utilizado nessa pesquisa é o Celeb-DF v2 Li et al. (2020), um conjunto de vídeos em alta qualidade com gravações de diferentes celebridades, possuindo uma ampla variação em de contextos e indivíduos. A base de dados possui ao todo 6479 vídeos, onde 890 são vídeos reais, sendo 300 vídeos do YouTube e 590 de celebridades. Já os outros 5639 vídeos são vídeos falsos sintetizados a partir dos vídeos de celebridades, onde foram aplicadas técnicas de *deepfakes*, como o *face swap*.

Realizando uma análise dos vídeos, percebe-se que a taxa de quadros dos mesmos não é consistente para toda a base de dados, variando de 28,75 a 30,0 quadros por segundo. Em relação à duração dos vídeos, as diferenças observadas são mais consideráveis, onde o vídeo mais curto possui um único quadro e o mais longo possui 740 quadros. Considerando que o presente trabalho analisará os vídeos como uma sequência de quadros, e não como imagens individuais, tal vídeo será desconsiderado.

A duração média dos vídeos é de 379 quadros, o que corresponde a aproximadamente 12,6 segundos de duração em uma taxa de 30 quadros por segundo, todavia há um grande desvio padrão no tamanho dos vídeos, sendo de 84,7 quadros, quase três segundos de variação.

Além disso, a resolução espacial dos vídeos também varia. Em média, as dimensões dos quadros são de 813 pixeis de largura por 480 pixels de altura.

3.2 Pré-processamento

Dado o nosso foco em avaliar a viabilidade do uso de segmentos de vídeo mais curtos, adotamos uma estratégia baseada em trechos de 24 quadros, o que corresponde a aproximadamente um segundo de vídeo. Essa escolha ajuda a reduzir a complexidade do modelo, aumentando a eficiência computacional sem comprometer o desempenho.

Devido ao desequilíbrio natural do conjunto de dados, no qual os vídeos reais estão significativamente sub-representados, aplicamos uma estratégia de aumento de dados para mitigar essa desproporção. Nos conjuntos de treinamento e validação, a proporção de vídeos reais para falsos é

de 712 para 5299. Para lidar com esse desequilíbrio, extraímos apenas um segmento de 24 quadros de cada vídeo falso, enquanto geramos múltiplos segmentos a partir dos vídeos reais.

O conjunto de teste é composto por 178 vídeos reais e 340 vídeos falsos, conforme pré-selecionado pelos autores da Celeb-DF. Essa divisão predefinida foi mantida para garantir a reprodutibilidade dos experimentos e permitir comparações diretas com resultados existentes.

Para construir um conjunto de dados balanceado para treinamento e validação, foi necessário tratar a disparidade no número de vídeos reais. Uma solução prática foi gerar múltiplos subsegmentos a partir de cada vídeo real original. Inicialmente, o conjunto de validação foi configurado para conter o mesmo número de vídeos falsos do conjunto de teste (isto é, 340). No entanto, essa configuração levou a um desequilíbrio significativo nos dados de treinamento. Por meio de inspeção manual, foi determinado que transferir 14 vídeos falsos do conjunto de validação para o conjunto de treinamento melhoraria o equilíbrio, resultando em um conjunto de validação final com 326 vídeos falsos e 163 vídeos reais.

Com o objetivo de igualar o número de vídeos reais e falsos no conjunto de validação, dois segmentos de 24 quadros foram extraídos de cada vídeo real. Para o treinamento, utilizamos 4973 clipes de vídeos falsos e extraímos nove segmentos de 24 quadros de cada um dos 549 vídeos reais, totalizando 4932 segmentos por classe, garantindo um conjunto de treinamento balanceado.

É importante observar que o aumento de dados é aplicado apenas durante o treinamento e a validação, não afetando as métricas de avaliação final. Além disso, os segmentos são não se sobrepõem e são extraídos de forma sequencial, isto é, cada um começa exatamente após o final do anterior.

Para ser incluído no conjunto de validação, um vídeo precisava ter pelo menos 48 quadros, o suficiente para dois segmentos de 24 quadros. Para inclusão no conjunto de treinamento, o mínimo necessário era de 216 quadros, correspondendo a nove segmentos. Um vídeo contendo apenas um quadro foi excluído do conjunto de dados. Vídeos com duração entre 48 e 215 quadros foram atribuídos exclusivamente ao conjunto de validação, totalizando sete instâncias.

Todos os vídeos restantes foram atribuídos aleatoriamente aos conjuntos de treinamento ou validação antes da extração dos segmentos. Isso garantiu que nenhum vídeo contribuísse com clipes para ambos os conjuntos, mantendo uma separação rigorosa entre os dados de treinamento e validação. A Tabela 2 apresenta um resumo do número de vídeos incluídos em cada subconjunto

do conjunto de dados.

	Real	Falso	Total
Treino	$548 \times 9 = 4932$	4973	9905
Validação	$163 \times 2 = 326$	326	652
Teste	178	340	518
Total	5436	5639	11075

Tabela 2: Divisão dos vídeos.

Seguindo a metodologia proposta em de Lima et al. (2020); **?**, as regiões faciais foram extraídas dos vídeos com um preenchimento adicional de 10%. Essa abordagem evita recortes excessivamente justos e fornece informações contextuais adicionais. As faces extraídas foram redimensionadas para uma resolução fixa de 299×299 pixels, preservando a razão altura X largura original, a fim de evitar distorções causadas por interpolação. Qualquer espaço extra resultante desse redimensionamento foi preenchido com zeros (bordas pretas), em contraste com trabalhos anteriores onde a face normalmente ocupava toda a imagem.

A detecção e extração das faces foram realizadas utilizando o modelo RetinaFace **?**, escolhido por sua alta precisão e baixa taxa de falsas detecções em comparação com outros modelos disponíveis, conforme apontado em de Lima et al. (2020).

A Figura 1 ilustra o processo de extração facial mantendo a proporção original. Se a altura ou largura da face excedesse 299 pixeis, ela era redimensionada proporcionalmente, limitando a maior dimensão a 299 pixeis. Por exemplo, na Figura 1(c), a altura original excedia o limite do quadro e foi ajustada de forma correspondente.

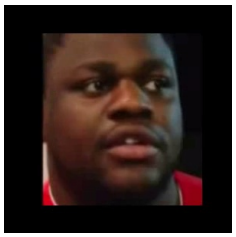
Figura 1: Imagem original em (a), recorte matnendo a proporção em (b).



(a) (b)

Nos casos em que a região de interesse era menor que 299×299, a face era centralizada no quadro, e o espaço restante era preenchido com bordas pretas, conforme ilustrado na Figura 2.

Figura 2: Área de interesse menor que 299×299.



3.3 Modelo Proposto

Entre os diferentes modelos bases explorados na Seção 2, a Xception é um dos que obtiveram o menor uso, sendo explorada em Khormali & Yuan (2021), onde foram apresentados resultados extremamente competitivos e próximos aos melhores resultados, gerando um espaço de possibilidades para melhorias.

Em sua implementação, há a presença de convolução separável em profundidade, que, diferente da convolução convencional que funciona aprendendo diferentes filtros para os diferentes canais das imagens, em tal variação, a convolução é quebrada em duas partes: 1) Convolução por profundidade, onde é aplicada uma convolução independente em cada canal de entrada; 2) Convolução ponto a ponto, onde é aplicada uma convolução de filtro 1×1 para combinar os resultados dos diferentes canais. Dessa forma, o número de parâmetros é reduzido, favorecendo o desempenho computacional.

A Xception pode ser dividida em três grandes partes que utilizam conexões residuais e convoluções separáveis em profundidade: 1) Fluxo de entrada, que recebe imagens RGB de tamanho 299×299, extraindo informações dos dados de entrada; 2) Fluxo central, que possui três blocos de ReLU seguidas por camadas de Convolução separável, possuindo, também uma conexão residual que liga a entrada ao final do terceiro bloco, repetindo oito vezes essa estrutura; 3) Fluxo de saída, que possui, em seu final, uma camada densa com regressão logística.

Como definido anteriormente, os vídeos trabalhados serão compostos por 24 imagens, todavia a Xception trabalha com uma só por vez, tornando necessário uma adaptação do modelo para que ele funcione com uma sequência de dados. Uma alternativa factível é a utilização de uma camada *TimeDistributed*, uma camada que aplica a mesma arquitetura alvo em todos os dados da sequência. Como resultado, é obtido um tensor de quatro dimensões que possui informações da relação entre espaço e tempo dos dados.

Para que esses dados sejam utilizados em um classificador, é necessário passá-los para uma camada de neurônios. Todavia as dimensões atuais não permitem essa conexão. Assim, faz-se necessário a diminuição do tensor, podendo ser feito a partir de uma linearização dos dados, mas que geraria uma enorme quantidade de parâmetros, inviabilizando o processo. Por outro lado, é possível realizar um *GlobalAveragePooling3D* nos dados, reduzindo as informações ao mesmo passo em que mantém informações relevantes.

Em seguida, uma camada de saída totalmente conectada é aplicada. Todavia descobrir a quantidade de neurônios adequada não é uma tarefa simples, podendo ser utilizado técnicas de otimização de hiper-parâmetros para facilitar esse processo. Dessa forma, é explorada a quantidade de de neurônios para tal camada de forma que varie entre 256 a 400 com incrementos de 16, utilizando a função de ativação ReLU.

Ademais, a otimização dos hiper-parâmetros de treinamento também foi considerada essencial. Para isso, foram ajustados: (i) a taxa de aprendizado, amostrada logaritmicamente entre 1×10^{-4} e 1×10^{-2}; (ii) o parâmetro de *momentum*, amostrado logaritmicamente entre 0,87 e 0,92; e (iii) o uso da variante de *momentum* de Nesterov no otimizador SGD, como uma opção booleana. Esse processo foi realizado utilizando a biblioteca KerasTuner com a técnica de otimização Bayesiana. O processo de otimização foi limitado a um máximo de 20 rodadas de treinamento, com parada antecipada empregada para encerrar qualquer rodada caso o erro da validação não melhorasse por sete épocas consecutivas.

A arquitetura final resultante do processo de ajuste de hiper-parâmetros é apresentada na Figura 3. O modelo recebe tensores de entrada com dimensões $24 \times 299 \times 299 \times 3$, correspondendo a sequências de 24 quadros RGB, cada um com resolução espacial de 299×299 pixels. A dimensão temporal (24 quadros) é tratada por uma camada TimeDistributed. Essa operação gera uma saída intermediária com forma $24 \times 10 \times 10 \times 2048$.

Figura 3: Modelo Final



Fonte: *Imagem do autor*

Para agregar essas características espaço-temporais, aplica-se uma camada GlobalAveragePooling3D, reduzindo a representação para um único vetor com 2048 características. Esse vetor é então passado por uma camada densa totalmente conectada com 304 neurônios e ativação ReLU. A classificação final é realizada por uma camada de saída com dois neurônios e função de ativação softmax, permitindo ao modelo atribuir probabilidades de classe às categorias *autêntico* e *manipulado*.

4 Resultados

4.1 Configurações de experimentos

A implementação foi realizada utilizando a linguagem de programação Python. O framework TensorFlow (versão 2.15) foi empregado para o modelo *Xception* e o KerasTuner (versão 1.4.7) foi utilizado para o ajuste de hiperparâmetros.

O treinamento do modelo foi conduzido ao longo de 15 épocas. Os hiperparâmetros obtidos para o treinamento foram:

- Número de neurônios na camada densa: 304.
- Taxa de aprendizado: 7.1030×10^{-4}.
- Momentum: 0,9144.
- Momentum de Nesterov: `False`.

4.2 Resultados

Durante o processo de validação, o modelo atingiu uma acurácia máxima de 97,39% e uma AUC de 0,9876, conforme ilustrado na Figura 4. Vale destacar que a menor perda de validação ocorreu na sexta época, a qual também correspondeu à maior acurácia de treinamento. No entanto, a maior acurácia de validação foi observada na época 13. Assim, os pesos do modelo obtidos na época 13 foram selecionados para a avaliação final. Utilizando esses pesos, o modelo alcançou uma acurácia final de 97,30% e uma AUC de 0,9957 nos dados de teste.

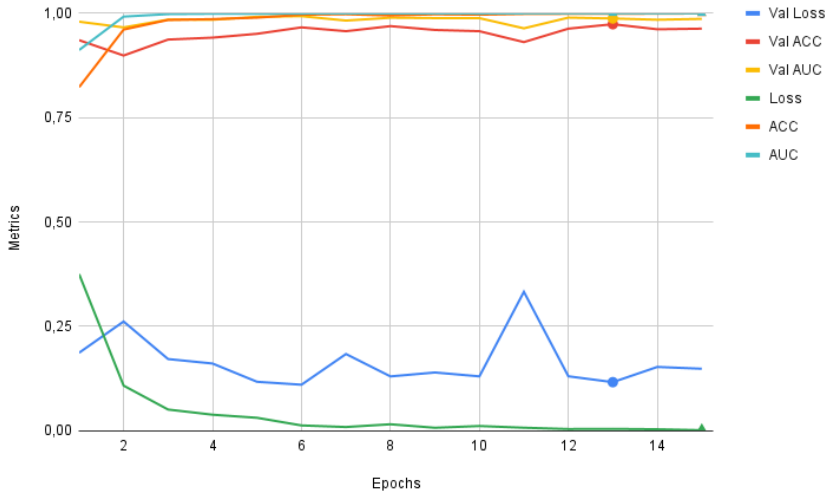


Figura 4: Resultados obtidos ao longo das quinze épocas.

Por fim, ao comparar esses resultados com os reportados em trabalhos relacionados que também utilizam o conjunto de dados Celeb-DF v2, conforme apresentado na Tabela 3, é evidente que o modelo proposto alcança um desempenho competitivo em termos de acurácia e AUC.

Trabalho	Quadros utilizados	Acurácia	AUC
H.-S. Chen et al. (2021)	7	Não informado	0,906
Yermakov et al. (2025)	32	Não informado	0,966
Khormali & Yuan (2021)	Não informado	Não informado	0,987
Heo et al. (2023)	32	Não informado	0,9930
Reis & Ribeiro (2024)	50 + 50×9	97,50%	0,994
Modelo proposto	24	97,30%	0,9957
Hernandez-Ortega et al. (2022)	210	99,47%	0,9999

Tabela 3: Comparação com métodos da literatura avaliados no Celeb-DF v2, ordenados por AUC.

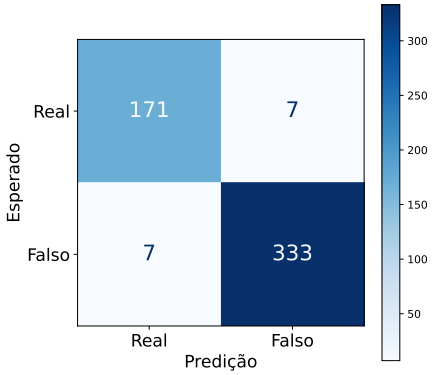
Embora a estratégia proposta não alcance a maior acurácia entre todos os métodos relacionados no Celeb-DF v2, ela opera utilizando o segundo menor número de quadros, ou seja, com menos dados, resultando em um custo computacional potencialmente menor, ao mesmo tempo em que mantém acurácia e AUC competitivas.

4.3 Discussão dos resultados

A Figura 5 apresenta a matriz de confusão resultante da avaliação no conjunto de teste. O modelo obteve uma taxa de erro de classificação de 2,70%, correspondente a 14 vídeos. Dentre

esses, sete vídeos autênticos foram incorretamente classificados como falsos, enquanto sete vídeos falsos foram classificados incorretamente como reais. Apesar do desbalanceamento significativo de classes no conjunto de dados, a matriz de confusão demonstra que o modelo foi capaz de aprender efetivamente os padrões discriminativos e alcançar um alto desempenho de classificação.

Figura 5: Matriz de confusão do conjunto de teste



Na Figura 6 exibimos um quadro de cada um dos vídeos reais que foram classificados como falsos. É possível notar que alguns vídeos foram redimensionados para se ajustarem ao limite de 299 pixeis da região facial, ou já eram originalmente de baixa resolução. No primeiro caso, uma possível explicação para a classificação incorreta é que o processo de redimensionamento pode ter causado agregação de pixeis, apagando características relevantes e dificultando a capacidade do modelo de identificar corretamente o vídeo como genuíno. No segundo caso, em que a resolução original já era baixa, o modelo pode ter carecido de informações visuais suficientes para detectar os padrões necessários para uma classificação precisa, levando a predições incorretas.

Figura 6: Reais classificados como falsos



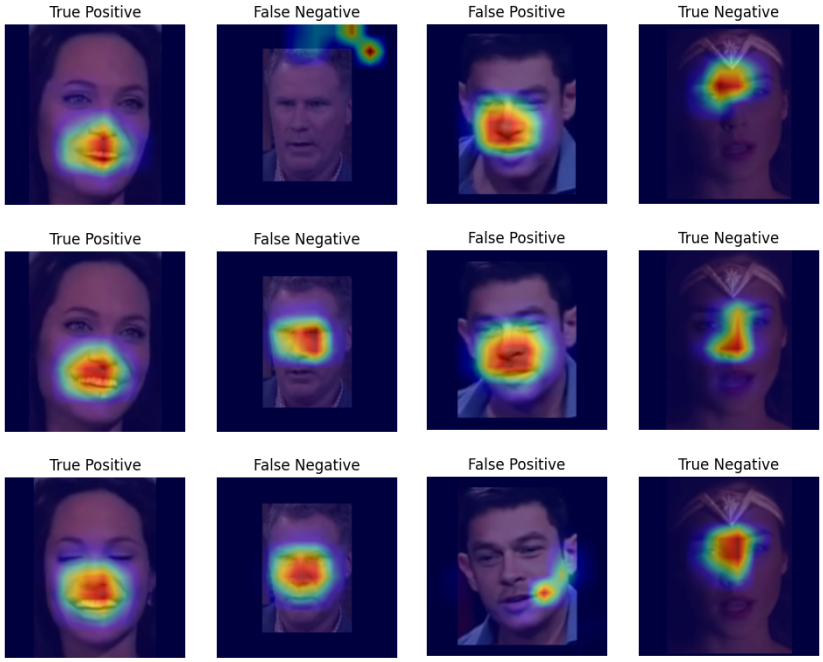
A Figura 7 apresenta um quadro de cada vídeo falso que foi incorretamente classificado como real. Nesses exemplos, pode-se observar que as imagens já eram menores do que o limite de 299 pixeis, evidenciado pela presença de margens pretas ao redor das regiões faciais. Essa resolução reduzida provavelmente comprometeu a capacidade do modelo de detectar artefatos específicos de *deepfake*, contribuindo para a classificação incorreta.

Figura 7: Falsos classificados como reais



A Figura 8 exibe os mapas de ativação Grad-CAM para o primeiro quadro, um quadro intermediário (o décimo segundo) e o quadro final de um vídeo. Esses quadros foram selecionados para ilustrar como o modelo proposto interpreta e classifica diferentes segmentos ao longo do vídeo.

Figura 8: Mapas de ativação do primeiro quadro (primeira linha), do quadro intermediário (segunda linha, décimo segundo quadro) e do quadro final de quatro vídeos e suas classificações.



Cores mais próximas do vermelho indicam uma maior relevância da região durante o processo de classificação, enquanto as áreas em azul representam regiões menos significativas. Assim, percebe-se que a análise não se concentra em uma única região, se deslocando para outras conforme o vídeo é avançado. Esse comportamento sugere uma estratégia de análise específica por quadro, em vez de uma abordagem global, o que é consistente com o fato de que as regiões manipuladas geralmente variam à medida que o vídeo avança e nem sempre permanecem as mesmas.

5 Conclusão e Trabalhos futuros

Os resultados obtidos evidenciam a capacidade de generalização do modelo na distinção entre vídeos reais e falsos, reforçando a importância do ajuste eficaz de hiper-parâmetros. Embora não supere todas as abordagens de ponta em desempenho bruto, a solução proposta destaca-se pela reprodutibilidade e transparência metodológica, comprovando que é possível alcançar detecção precisa de deepfakes utilizando segmentos curtos de vídeo e arquiteturas leves, sem recorrer a técnicas mais custosas.

Com apenas 24 quadros por vídeo, o modelo alcançou 97,30% de acurácia e AUC de 0,9957 no Celeb-DF-V2, resultados comparáveis aos da literatura, mesmo em cenários com recursos computacionais limitados. Sua arquitetura, capaz de processar todos os quadros simultaneamente e explorar a consistência temporal da sequência, contribuiu para esse desempenho.

Como trabalhos futuros, sugere-se investigar o uso de camadas TimeDistributed aplicadas a vídeos não recortados, evitando custos de pré-processamento, e explorar Vision Transformers como alternativa para aprimorar a classificação.

Referências

Chen, H., & Magramo, K. (2024, Feb). *Finance worker pays out $25 million after video call with deepfake chief financial officer.* CNN. Retrieved from https://edition.cnn.com/2024/02/04/asia/deepfake-cfo-scam-hong-kong-intl-hnk/index.html

Chen, H.-S., Rouhsedaghat, M., Ghani, H., Hu, S., You, S., & Kuo, C. C. J. (2021). *Defakehop: A light-weight high-performance deepfake detector.* Retrieved from https://arxiv.org/abs/2103.06929

de Lima, O., Franklin, S., Basu, S., Karwoski, B., & George, A. (2020). *Deepfake detection using spatiotemporal convolutional networks.* Retrieved from https://arxiv.org/abs/2006.14749

Heidari, A., Navimipour, N., Dag, H., & Unal, M. (2023, 11). Deepfake detection using deep learning methods: A systematic and comprehensive review. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, *14*. doi: 10.1002/widm.1520

Heo, Y.-J., Yeo, W.-H., & Kim, B.-G. (2023, Apr 01). Deepfake detection algorithm based on improved vision transformer. *Applied Intelligence*, *53*(7), 7512-7527. Retrieved from https://doi.org/10.1007/s10489-022-03867-9 doi: 10.1007/s10489-022-03867-9

Hernandez-Ortega, J., Tolosana, R., Fierrez, J., & Morales, A. (2022). Deepfakes detection based on heart rate estimation: Single- and multi-frame. In C. Rathgeb, R. Tolosana, R. Vera-Rodriguez, & C. Busch (Eds.), *Handbook of digital face manipulation and detection: From deepfakes to morphing attacks* (pp. 255–273). Cham: Springer International Publishing. Retrieved from https://doi.org/10.1007/978-3-030-87664-7_12 doi: 10.1007/978-3-030-87664-7_12

Khan, M., & Alam, K. N. (2022, 07). Detecting deepfake images using deep learning techniques and explainable ai methods. *Intelligent Automation and Soft Computing*, *35*. doi: 10.32604/iasc.2023.029653

Khormali, A., & Yuan, J.-S. (2021). Add: Attention-based deepfake detection approach. *Big Data and Cognitive Computing*, *5*(4). Retrieved from https://www.mdpi.com/2504-2289/5/4/49 doi: 10.3390/bdcc5040049

Li, Y., Yang, X., Sun, P., Qi, H., & Lyu, S. (2020). Celeb-df: A large-scale challenging dataset for deepfake forensics. In *Ieee conference on computer vision and patten recognition (cvpr)*.

Masud, U., Sadiq, M., Masood, S., Ahmad, M., & El-Latif, A. A. A. (2023, Nov). Lw-deepfakenet: a lightweight time distributed cnn-lstm network for real-time deepfake video detection. *Signal, Image and Video Processing*, *17*(8), 4029–4037. Retrieved from https://doi.org/10.1007/s11760-023-02633-9 doi: 10.1007/s11760-023-02633-9

Mirsky, Y., & Lee, W. (2021, January). The creation and detection of deepfakes: A survey. *ACM Computing Surveys*, *54*(1), 1–41. Retrieved from http://dx.doi.org/10.1145/3425780 doi: 10.1145/3425780

Reis, P. M. G. I., & Ribeiro, R. O. (2024). A forensic evaluation method for deepfake detection using dcnn-based facial similarity scores. *Forensic Science International*, *358*, 111747. Retrieved from https://www.sciencedirect.com/science/article/pii/S0379073823001974 doi: https://doi.org/10.1016/j.forsciint.2023.111747

Saikia, P., Dholaria, D., Yadav, P., Patel, V., & Roy, M. (2022). *A hybrid cnn-lstm model for video deepfake detection by leveraging optical flow features.* Retrieved from https://arxiv.org/abs/2208.00788

Yermakov, A., Cech, J., & Matas, J. (2025). *Unlocking the hidden potential of clip in generalizable deepfake detection.* Retrieved from https://arxiv.org/abs/2503.19683