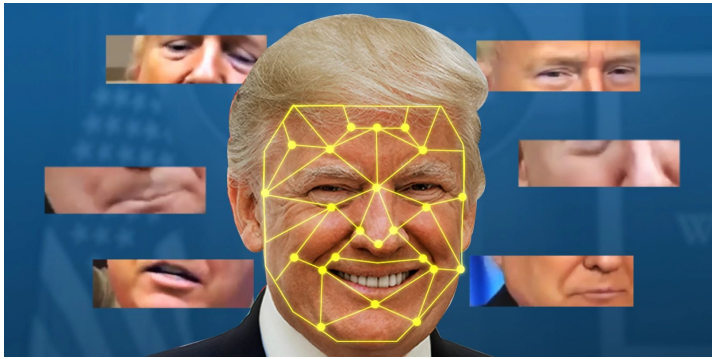
DETECÇÃO DE *DEEPFAKES*

Discentes: Felipe Braz, Matheus Peixoto, Nicolas Mendes e Vitor Oliveira
Docente: Guillermo Cámara Chávez
BCC326 - Processamento de Imagens
Departamento de Computação
Universidade Federal de Ouro Preto

Introdução

- Deepfake = “deep learning” + “fake”
- Utilização de redes neurais profundas para geração de mídias altamente realistas (manipulação de rostos e vozes)



Fonte: PUBLICA (2020)

Dataset

- Celeb-DF v2 **[Li et al. (2020)],** um conjunto de vídeos em alta qualidade com gravações de diferentes celebridades, variando contextos e indivíduos
- A base de dados possui ao todo **6479 vídeos**, onde **890 são vídeos reais**, sendo **300 vídeos do YouTube e 590 de celebridades**
- **5639 vídeos falsos** sintetizados a partir dos vídeos verdadeiros das celebridades



Fonte: ResearchGate(2025)

Pré-processamento

- Analisar trechos de **24 quadros** (reduz complexidade de modelo e ganho eficiência computacional)
- Conjunto de teste: **178** vídeos reais e **340** vídeos falsos (definido pelos autores do dataset; reprodutibilidade dos experimentos e comparações com outros trabalhos)
- Dataset desequilibrado: **712** vídeos reais e **5299** falsos
- Um vídeo possuía um quadro e foi removido

Pré-processamento

- Equilíbrio do número de vídeos: foi extraído **apenas um trecho de 24 quadros** de cada vídeo falso, enquanto foram gerados **vários trechos de 24 quadros** a partir dos vídeos reais
- Todos os vídeos restantes foram **atribuídos aleatoriamente** aos conjuntos de treinamento ou validação antes da extração dos segmentos.

	Real	Falso	Total
Treino	$548 \times 9 = 4932$	4973	9905
Validação	$163 \times 2 = 326$	326	652
Teste	178	340	518
Total	5436	5639	11075

Tabela 2: Divisão dos vídeos.

Pré-processamento

- Extração das faces com **RetinaFace** e adição de uma área de 10%
- Faces redimensionadas para uma resolução fixa de **299×299,** mantendo o aspect ratio
- Se a imagem possui mais de **299** px, redimensiona para 299px pela maior dimensão
- Se a imagem for menor, adiciona um padding ao redor

Figura 1: Imagem original em (a), recorte matnendo a proporção em (b).



(a) (b)

Figura 2: Área de interesse menor que 299 × 299.



Treinamento do Modelo

- A Xception é feita para trabalhar com imagens e não com vídeos
- Envolver a Xception na camada TimeDistributed
    - Aplica a mesma arquitetura alvo em todos os dados da sequência
- GlobalAveragePooling3D para linearizar os dados
- Camada densa com ativação ReLU seguida de outra camada com dois neurônios

Treinamento do Modelo

- Tunagem de hiper-parâmetros com Busca Bayesiana para o otimizador SGD
  - Número de neurônios: 256 a 400 com incremento linear de 16
  - Learning rate: 1×10^{-4} a 1×10^{-2} com distribuição logarítmica
  - Momentum: 0,87 a 0,92 com distribuição logarítmica
  - Nesterov: Booleano

Treinamento do Modelo

- Tunagem de hiper-parâmetros com Busca Bayesiana para o otimizador SGD
  - **Número de neurônios:** 304
  - **Learning rate:** $7{,}1030 \times 10^{-4}$
  - **Momentum:** 0,9144
  - **Nesterov**: Falso

Figura 3: Modelo Final



Fonte: *Imagem do autor*

```python
def build_model():
    base_model = Xception(include_top=False, weights='imagenet')
    for layer in base_model.layers:
        layer.trainable = True

    x = input_layer = Input(shape=(24, 299, 299, 3))
    x = TimeDistributed(base_model)(x)
    x = GlobalAveragePooling3D()(x)
    x = Dense(304, activation = 'relu')(x)
    output = Dense(2, activation='softmax')(x)

    model = Model(inputs=input_layer, outputs=output)

    model.compile(
        optimizer = SGD(
            learning_rate = 0.0007103089732495943,
            momentum = 0.9143924269674935,
            nesterov = False
        ),
        loss='categorical_crossentropy',
        metrics=['accuracy', 'AUC']
    )
```

Resultados Obtidos

- Usando os pesos da época 13, a acurácia final foi de **97,30%** e uma AUC de **0,9957** nos dados de teste.

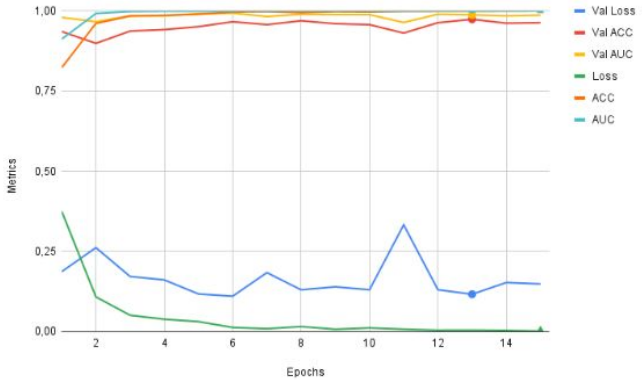


Figura 4: Resultados obtidos ao longo das quinze épocas.

Resultados Obtidos

- Ao comparar esses resultados com os trabalhos que também utilizam o conjunto de dados Celeb-DF v2;

Trabalho	Quadros utilizados	Acurácia	AUC
H.-S. Chen et al. (2021)	7	Não informado	0,906
Yermakov et al. (2025)	32	Não informado	0,966
Khormali & Yuan (2021)	Não informado	Não informado	0,987
Heo et al. (2023)	32	Não informado	0,9930
Reis & Ribeiro (2024)	50 + 50×9	97,50%	0,994
Modelo proposto	24	97,30%	0,9957
Hernandez-Ortega et al. (2022)	210	99,47%	0,9999

Tabela 3: Comparação com métodos da literatura avaliados no Celeb-DF v2, ordenados por AUC.

Discussão dos resultados

Figura 5: Matriz de confusão do conjunto de teste

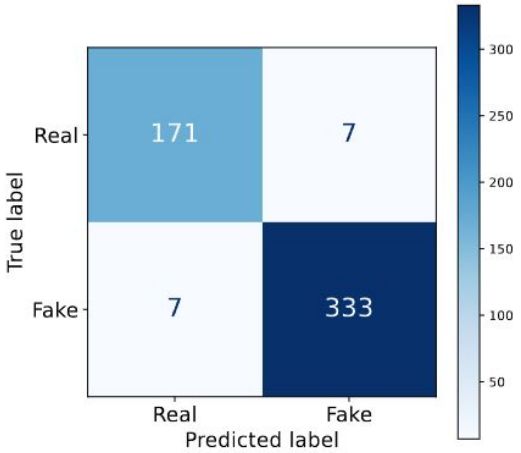
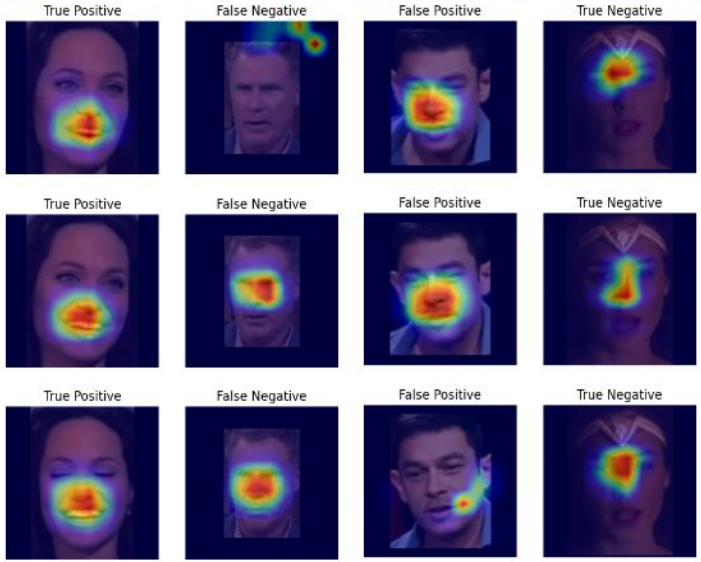


Figura 8: Mapas de ativação do primeiro quadro (primeira linha), do quadro intermediário (segunda linha, décimo segundo quadro) e do quadro final de quatro vídeos e suas classificações.



Referências

PUBLICA. *Yes, nós temos deepfake: brasileiros são o 2º maior público de aplicativo que troca rostos de políticos e celebridades*. 2020. Disponível em: <https://apublica.org/2020/08/yes-nos-temos-deepfake-brasileiros-sao-o-2o-maior-publico-de-aplicativo-que-troca-rostos-de-politicos-e-celebridades/>. Acesso em: 8 ago. 2025.

CHEN, H.; MAGRAMO, K. *Finance worker pays out $25 million after video call with deepfake chief financial officer*. CNN, 4 fev. 2024. Disponível em: <https://edition.cnn.com/2024/02/04/asia/deepfake-cfo-scam-hong-kong-intl-hnk/index.html>. Acesso em: 8 ago. 2025.