Plasticidade e Rigidez em Modelos de Embeddings Globais e Monolíngues para o Português Brasileiro

Matheus Peixoto Ribeiro Vieira

Universidade Federal de Ouro Preto, UFOP
Departamento de Computação, DECOM
Orientador: Pedro Henrique Lopes Silva
Coorientador: Eduardo José da Silva Luz



Summary

Introdução

Fundamentação teórica

Trabalhos relacionados

Metodologia

Resultados

Conclusão

Referências

Introdução

Processamento de Linguagem Natural

- Jogo da Imitação proposto por TURING (1950);
- Processamento de Linguagem Natural (PLN) é o processamento, análise e geração de texto;

Desafios

- Avanço em desafios:
  - Separar comentários normais e de ódio (**Classificação**)
  - Agrupar textos similares (**Clusterização**)
  - Classificar frase como implicação, negação ou neutra (**Inferência de Linguagem Natural - NLI**)
  - Medir a similaridade entre duas sentenças (**Similaridade de semântica textual - STS**)

Atenção

- *Attention is all you need* Vaswani et al. (2017)
- Inovações:
  - GPT: Geração de textos
  - BERT: Extração de características (Embeddings)
- LLMs

Falando português

- Modelos focados em português:
  - BERTimbau (SOUZA; NOGUEIRA; LOTUFO, 2020)
  - Sabiá (PIRES et al., 2023)
  - Canarim (Maicon Domingues, 2023)
  - Serafim (GOMES et al., 2024)
  - Bode (GARCIA et al., 2024)
- Menores e com alto desempenho



Fonte: Souza, Nogueira e Lotufo (2020)

Avaliando e Especializando

- Formas de avaliar um modelo:
  - *Linear-Probing*
  - *Fine-tuning*
- Adaptar todo um modelo pode ser custoso
- *Parameter-Efficient Fine-Tuning* (PEFT)

Pergunta de pesquisa central

Quão eficazes são adaptações leves e como é o seu comportamento em diferentes tarefas de downstream? Permanecem estáveis ou sofrem oscilações consideráveis?

Perguntas de Pesquisa

1. Como os modelos multilíngues e monolíngues se comparam no *linear-probing* e *fine-tuning*?
2. *Fine-tuning* é sempre benéfico?
3. Qual modelo escolher?

Objetivos

- **Objetivo Geral**: Analisar comparativamente o desempenho de modelos globais e monolíngues para o português brasileiro em regimes de *linear-probing* e sua versão especializada
- **Objetivos específicos**:
  - Avaliar a qualidade das representações geradas por meio do regime de *linear-probing*;
  - Investigar o impacto do *fine-tuning* eficiente utilizando técnicas de PEFT;
  - Comparar o comportamento dos modelos em diferentes tarefas, incluindo classificação, clusterização, NLI e STS;
  - Identificar possíveis *trade-offs* entre adaptação e desempenho;
  - Analisar o alinhamento dos modelos com a língua portuguesa.

Fundamentação teórica

Como o ChatGPT entende o texto?

- Como o ChatGPT entende o texto?
- As máquinas entendem números, não palavras

Tokens

- *Tokenização*: Quebra as palavras em pequenas partes (Tokens)
- *Tokens* definidos pelo vocabulário

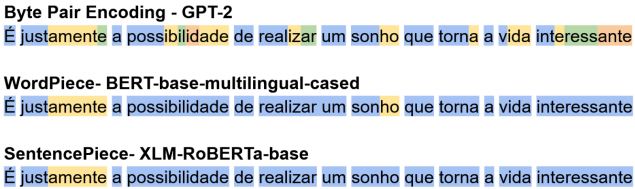


Figura: *Tokenização* da frase "É justamente a possibilidade de realizar um sonho que torna a vida interessante"para algoritmos BPE, WordPiece e SentencePiece

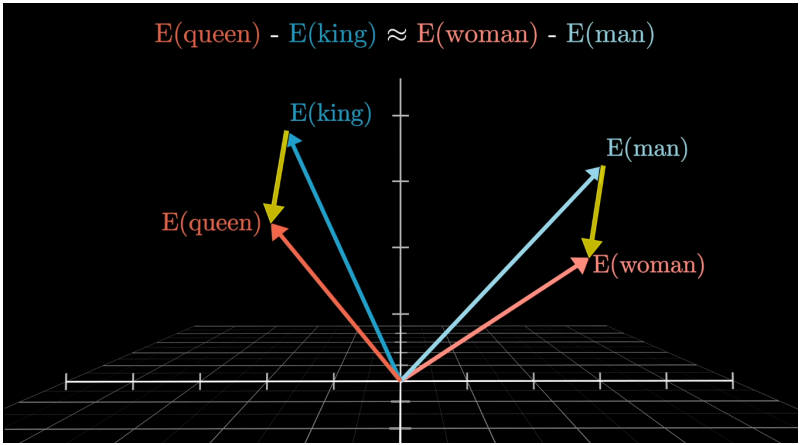
Representação numérica

- *Embeddings* com muitas dimensões
- Representação numérica para todo o vocabulário
- Espaço latente

aalh	aardvark	aardwolf	aargh	ab	aback	abacterial	abacus	abalone	abandon	⋯	zygoid	zygomatic	zygomorphic	zygosis	zygote	zygotic	zyme	zymogen	zymosis	zzz
+7.2	−5.1	+2.3	−3.5	−9.5	+5.4	−3.5	−2.3	+1.1	+5.9	⋯	+2.4	+7.4	−4.6	+6.0	−5.9	+8.8	+3.6	−5.6	+8.8	+4.5
−4.9	−5.7	+0.3	−9.4	−5.8	−1.5	−2.5	−0.7	−4.4	+1.7	⋯	+7.2	−7.6	+0.3	−7.3	+4.3	−2.1	+1.3	−6.3	−7.0	−0.2
−2.9	+8.7	+5.3	+4.9	+8.0	−8.2	+1.0	+1.7	+9.1	−4.1	⋯	−5.1	−7.9	−9.6	+8.5	+3.4	+5.6	−4.3	+1.7	−8.6	−0.3
+9.5	+7.5	−3.2	+9.1	−5.3	+8.9	+8.7	+5.9	+2.6	+7.4	⋯	−4.1	+6.9	+2.3	−9.6	−3.0	−7.0	+9.5	−0.4	−0.1	+2.8
−2.6	−7.2	+6.4	−6.1	+0.2	−5.5	−8.0	+7.2	+9.4	+9.1	⋯	+8.0	+5.4	−3.3	−8.3	−1.8	−5.3	−7.3	−8.8	+4.5	−9.7
+5.4	−7.0	−8.3	−8.1	+3.4	−5.0	−1.6	+1.1	+7.1	+4.5	⋯	−4.5	−7.3	−8.8	−3.9	−4.7	−0.9	+3.6	+3.9	−4.3	−2.4
−6.3	+5.7	−8.8	+3.9	+5.5	+5.5	−4.8	−2.5	+1.7	−4.5	⋯	−2.6	−6.0	−0.8	−9.0	+5.9	−8.4	+0.4	−3.8	+1.5	+9.1
+2.9	−9.2	−1.4	+0.2	+0.7	+3.6	−4.4	−7.3	−2.1	+9.0	⋯	−6.2	+8.0	+0.9	−0.9	+7.6	−0.8	+4.4	−2.0	+8.0	+3.8
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋱	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
+4.0	−3.4	+5.1	+2.7	−5.1	−6.7	+5.9	+9.1	−0.8	+1.8	⋯	+7.1	−0.8	+8.9	+1.5	+6.4	+8.1	+6.2	−6.7	+2.6	−2.0

Fonte: Sanderson (2024)

Embedding



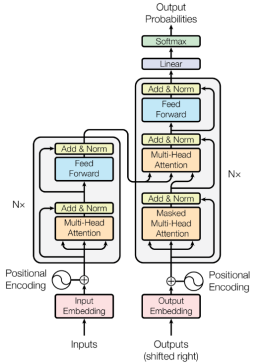
Fonte: Sanderson (2024)

Geração de Embeddings

- BERT - *Embeddings* Contextualizados (DEVLIN et al., 2019)
- Olha para todas as direções
- Valores diferentes para homônimos perfeitos

Transformers

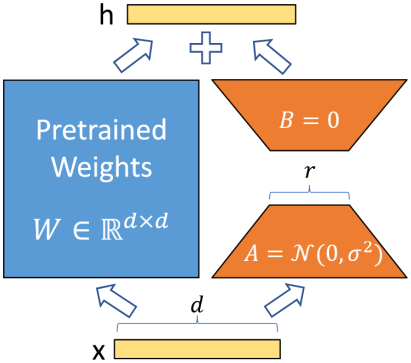
- Usam *embeddings* para entender o texto
- Blocos de atenção:
  - *Query* e *Key* para analisar a relação das palavras
  - *Value* para modificar o *embedding*
- *Key*, *Query* e *Value* são matrizes



Fonte: Vaswani et al. (2017)

LoRA

- Adaptação completa pode ser cara
- Uso de PEFT com LoRA (HU et al., 2021):
  - Divide a matriz em duas
  - Novas matrizes pequenas e com menos parâmetros
  - Altera os novos parâmetros e soma ao modelo original



Fonte: Hu et al. (2021)

Trabalhos relacionados

Monolíngues ou Multilíngues

- Virtanen et al. (2019) treinou o mBERT para o finlandês e obteve bons resultados.
- Souza, Nogueira e Lotufo (2020) propôs o BERTimbau que gera também excelentes resultados para o português
- Wu e Dredze (2020), Ghosh e Senapati (2025) e Kostić, Batanović e Nikolić (2023) mostram que modelos multilíngues possuem excelentes resultados para línguas com poucos recursos. E os monolíngues se dão melhor em línguas com mais dados de treinamento.

Tokens

- Petrov et al. (2023) analisou *tokenizadores* de múltiplas línguas
  - O português gera 1,5 *tokens* a mais que o inglês
  - Sinhala e Santoli geram 12 a 13 vezes mais
  - Shan com quase 18 vezes mais *tokens*

Metodologia

Modelos Explorados

Tabela: Resumo dos modelos utilizados

Família	Arquitetura	Tamanho do vocabulário	Parâmetros
Albertina PT-BR	Encoder	128k	139M 887M
BERTimbau	Encoder	29k	110M 335M
Gemma	Decoder	256k	2B
Qwen	Decoder	152k	596M
Serafim	Encoder	29k	335M
ST MiniLM	Encoder	250k	118M
Tucano	Decoder	32k	650M

Fonte: *Tabela do autor*.

Conjuntos de dados

Tabela: Tarefas, métricas e conjunto de dados explorados

Tarefa	Métrica	Conjunto de dados	Instâncias de teste
Classificação	Acurácia	AG News PT	7600
		TuPyE	8734
		HateBR	1400
Clustering	AMI	AG News PT	7600
		TuPyE	8734
		HateBR	1400
NLI	Acurácia	Assin2	2448
STS	Pearson & Spearman	ASSIN	4000
		Assin2	2448
Análise de tokens	-	Em Ambiente Real	14

Fonte: *Tabela do autor*

Regimes de avaliação

- ***Linear-Probing***
  - Classificação e NLI: Regressão logística e 5000 iterações de treinamento
  - Clusterização: Algoritmo K-médias
  - STS: Similaridade de cosseno
- ***Fine-tuning* leve**:
  - LoRA para modelos de classificação, STS e NLI
  - Alta eficiência computacional com baixo acréscimo de uso de memória

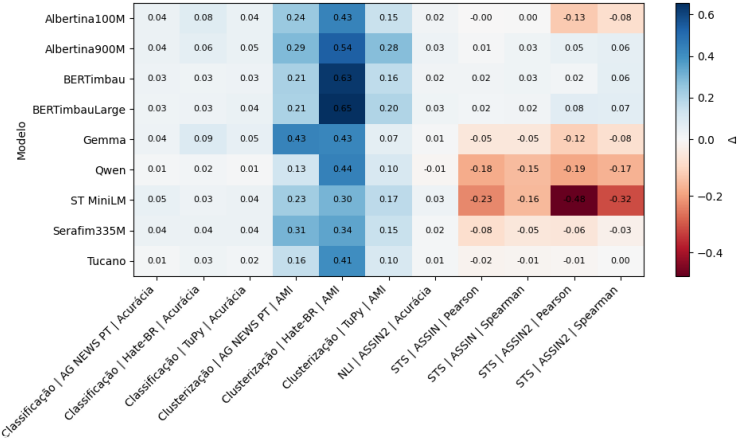
Análise da qualidade dos tokens

- Somente as métricas não contam toda a história
- **Análise quantitativa**
  - Quantidade média de tokens para cada *dataset*
  - Mais *tokens* = Maior fragmentação
- **Análise qualitativa**
  - Análise do conjunto "Em Ambiente Real"
  - Comparação dos *tokens* com a morfologia

Resultados

PP1: Linear-Probing vs Fine-tuning

Figura: Mapa de calor dos Δ's de variação da avaliação *linear-probing* e *fine-tuning*



PP1: Linear-Probing vs Fine-tuning - Classificação

Tabela: Resultados da classificação (acurácia) sobre regimes de *linear-probing* e *fine-tuning*.

Modelo	AG NEWS PT			Hate-BR			TuPy		
	Linear-Probing	Fine-tuning	Δ	Linear-Probing	Fine-tuning	Δ	Linear-Probing	Fine-tuning	Δ
Albertina100M	0,872	0,908	0,036	0,802	0,880	0,078	0,761	0,802	0,042
Albertina900M	0,897	**0,937**	0,040	0,848	0,909	0,061	0,774	0,819	0,045
BERTimbau	0,887	0,922	0,035	0,900	0,929	0,029	0,788	0,823	0,034
BERTimbauLarge	**0,898**	0,929	0,030	**0,902**	0,934	0,032	**0,789**	**0,830**	0,041
Gemma	0,887	0,922	0,035	0,824	0,916	**0,091**	0,763	0,818	**0,055**
ST MiniLM	0,871	0,921	**0,051**	0,844	0,879	0,034	0,761	0,800	0,039
Qwen	0,898	0,909	0,011	0,873	0,890	0,017	0,781	0,791	0,010
Serafim335M	0,887	0,927	0,040	0,898	**0,936**	0,039	0,788	0,828	0,040
Tucano	0,892	0,906	0,014	0,878	0,908	0,030	0,784	0,800	0,016

- BERTimbauLarge domina no Linear-Probing
- BERTimbauLarge, Serafim e Albertina se destacam no *fine-tuning*

PP1: Linear-Probing vs Fine-tuning - Clusterização

Tabela: Resultado do *clustering* (AMI) sobre regimes de *linear-probing* e *fine-tuning*.

Modelo	AG NEWS PT			Hate-BR			TuPy		
	Linear-Probing	Fine-tuning	Δ	Linear-Probing	Fine-tuning	Δ	Linear-Probing	Fine-tuning	Δ
Albertina100M	0,478	0,721	0,243	0,016	0,450	0,435	0,002	0,148	0,147
Albertina900M	0,514	**0,802**	0,289	0,022	0,559	0,536	0,002	**0,281**	**0,279**
BERTimbau	0,521	0,733	0,212	0,005	0,636	0,631	0,012	0,177	0,164
BERTimbauLarge	0,547	0,754	0,207	0,000	0,654	**0,654**	0,008	0,207	0,199
Gemma	0,277	0,712	**0,435**	0,004	0,430	0,426	0,001	0,066	0,065
ST MiniLM	0,526	0,753	0,226	0,152	0,457	0,305	0,007	0,177	0,171
Qwen	**0,588**	0,716	0,128	0,007	0,448	0,441	0,007	0,112	0,105
Serafim335M	0,446	0,752	0,306	**0,318**	**0,662**	0,343	**0,045**	0,191	0,146
Tucano	0,542	0,697	0,156	0,020	0,426	0,406	0,002	0,105	0,103

- Não há um modelo que se destaca mais
- Serafim tem bons resultados no Hate-BR

PP1: Linear-Probing vs Fine-tuning - NLI

Tabela: Resultados do NLI (Acurácia) no ASSIN2 sobre regimes de *linear-probing* e *fine-tuning*.

Dataset	Modelo	*Linear-Probing*	*Fine-tuning*	Δ
ASSIN2	Albertina100M	0,763	0,785	0,023
	Albertina900M	0,773	0,805	0,032
	BERTimbau	0,808	0,829	0,021
	BERTimbauLarge	0,772	0,800	0,029
	Gemma	0,724	0,732	0,008
	ST MiniLM	0,790	0,822	**0,032**
	Qwen	0,815	0,804	-0,011
	Serafim335M	**0,839**	**0,855**	0,015
	Tucano	0,769	0,779	0,011

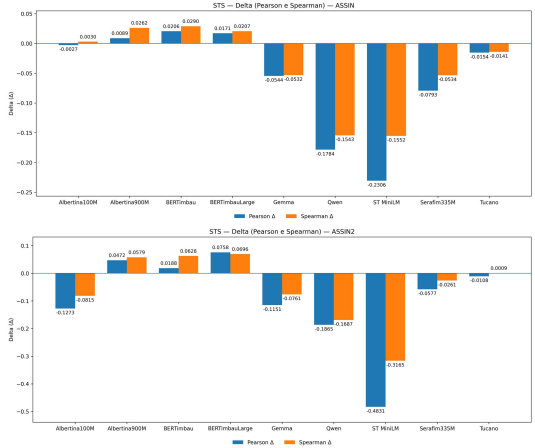
PP1: Linear-Probing vs Fine-tuning - STS

Tabela: Resultados do STS (Pearson e Spearman) sobre regimes de *linear-probing* e *fine-tuning*. Os melhores resultados por *dataset/regime estão em negrito*.

Dataset	Modelo	STS Pearson			STS Spearman		
		Linear-probing	Fine-Tuning	Δ	Linear-probing	Fine-Tuning	Δ
ASSIN	Albertina100M	0,584	0,581	-0,003	0,592	0,595	0,003
	Albertina900M	0,599	0,608	0,009	0,608	0,634	0,026
	BERTimbau	0,614	0,635	**0,021**	0,619	0,648	**0,029**
	BERTimbauLarge	0,582	0,599	0,017	0,597	0,618	0,021
	Gemma	0,395	0,340	-0,054	0,454	0,401	-0,053
	ST MiniLM	0,678	0,447	-0,231	0,679	0,524	-0,155
	Qwen	0,745	0,567	-0,178	0,739	0,585	-0,154
	Serafim335M	**0,809**	**0,730**	-0,079	**0,801**	**0,747**	-0,053
	Tucano	0,532	0,517	-0,015	0,541	0,527	-0,014
ASSIN 2	Albertina100M	0,614	0,487	-0,127	0,587	0,506	-0,082
	Albertina900M	0,601	0,648	0,047	0,565	0,623	0,058
	BERTimbau	0,672	0,690	0,019	0,614	0,677	0,063
	BERTimbauLarge	0,681	0,757	**0,076**	0,619	0,689	**0,070**
	Gemma	0,469	0,354	-0,115	0,466	0,390	-0,076
	ST MiniLM	0,772	0,289	-0,483	0,715	0,398	-0,317
	Qwen	0,805	0,618	-0,186	0,744	0,575	-0,169
	Serafim335M	**0,860**	**0,802**	-0,058	**0,832**	**0,806**	-0,026
	Tucano	0,561	0,550	-0,011	0,509	0,510	0,001

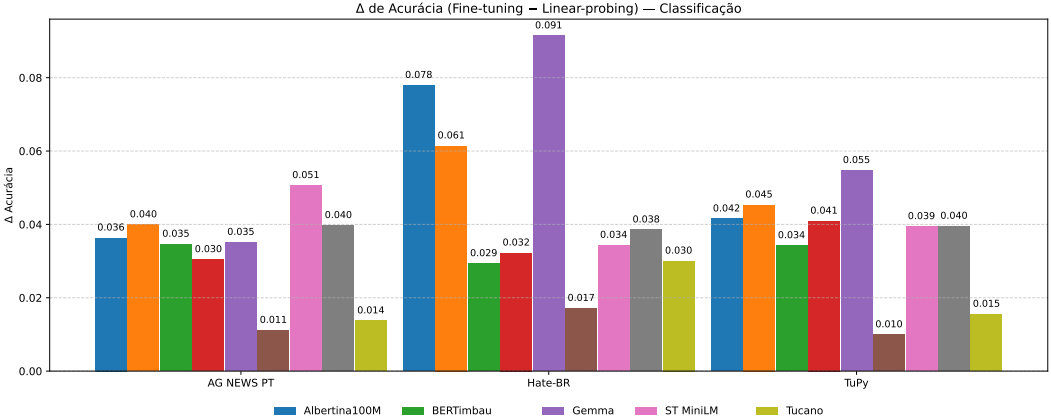
PP1: Linear-Probing vs Fine-tuning - STS

Figura: Delta entre *linear-probing* e *fine-tuning* para STS



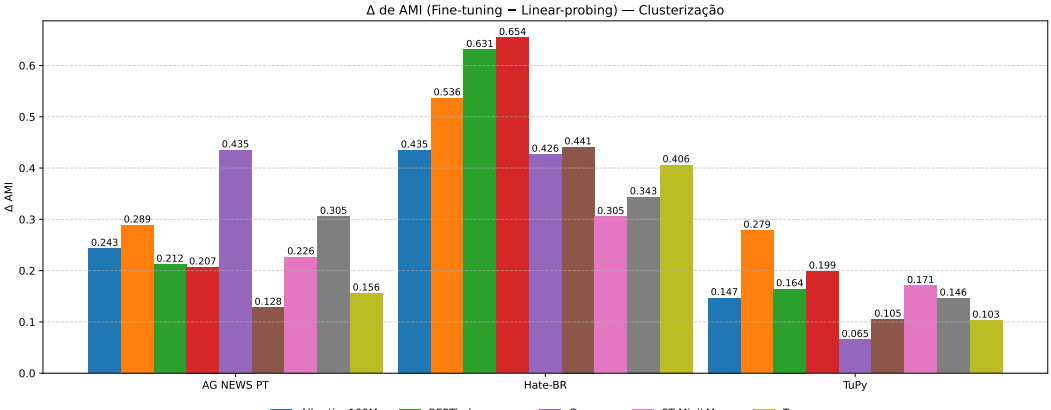
PP2: Dicotomia da Adaptação

Figura: Deltas de acurácia para os diferentes conjuntos de dados na tarefa de classificação



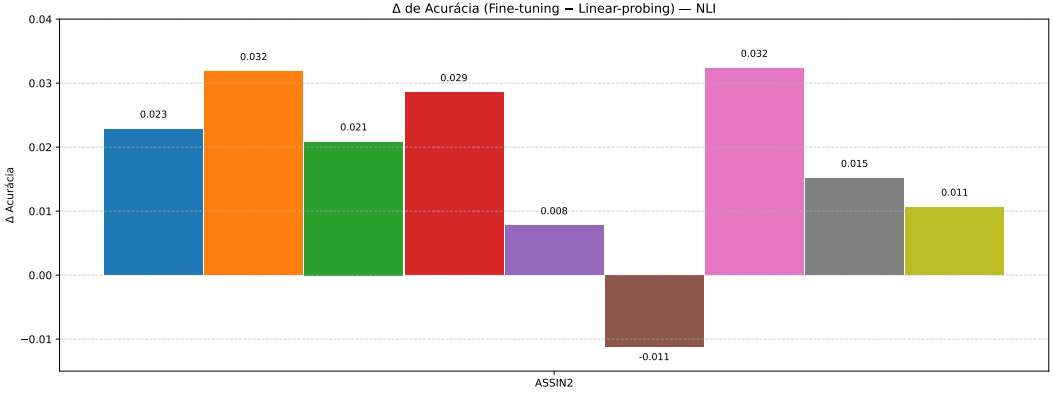
PP2: Dicotomia da Adaptação

Figura: Deltas de acurácia para os diferentes conjuntos de dados na tarefa de *clusterização*



PP2: Dicotomia da Adaptação

Figura: Deltas de acurácia para os diferentes conjuntos de dados na tarefa de NLI.



PP2: Dicotomia da Adaptação

- Modelos baseados em BERT (Albertina900M; BERTimbau) tiveram melhoras em todos os cenários;
- Plasticidade de adaptação: Espaço de *embeddings* menos restritivo

PP3: Qual modelo escolher?

- BERTimbauLarge é devagar, mas com resultados
- Serafim é próximo e mais rápido no AG NEWS PT
- BERTimbau possui um bom *trade-off* de velocidade e métricas

Tabela: Tempo de execução médio, em segundos, para cada conjunto de dados

Modelo	Classificação (segundos)		
	AG News PT	HateBR	TuPy
Albertina100m	1190,527	28,024	430,625
Albertina900m	1800,243	59,084	488,531
BERTimbau	795,823	12,967	**233,455**
BERTimbauLarge	1039,507	22,827	322,232
Gemma	3026,848	79,020	697,281
Qwen	1501,652	54,261	498,322
Serafim335m	982,286	22,415	325,077
ST MiniLM	**629,193**	**12,589**	288,648
Tucano	1412,694	28,883	352,823

PP3: Qual modelo escolher?

- ST MiniLM é rápido e impreciso
- BERTimbauLarge tem o melhor *trade-off*

Tabela: Tempo de execução médio, em segundos, para cada conjunto de dados

Modelo	Clusterização (segundos)		
	AG News PT	HateBR	TuPy
Albertina100m	33,371	7,391	38,395
Albertina900m	90,571	14,028	76,620
BERTimbau	15,831	3,865	18,483
BERTimbauLarge	31,081	5,985	31,059
Gemma	141,704	18,039	105,376
Qwen	61,007	12,210	67,097
Serafim335m	30,706	6,257	32,020
ST MiniLM	**13,017**	**2,826**	**14,678**
Tucano	43,048	7,917	40,038

PP3: Qual modelo escolher?

- Serafim tem o melhor balanço
- Esquecimento catastrófico do STS

Tabela: Tempo de execução médio, em segundos, para cada conjunto de dados

Modelo	NLI	STS	
	ASSIN2	ASSIN	ASSIN2
Albertina100m	71,356	31,394	18,826
Albertina900m	125,725	63,767	34,786
BERTimbau	**29,450**	**12,688**	8,069
BERTimbauLarge	51,820	22,369	13,877
Gemma	146,326	85,862	40,190
Qwen	131,940	57,971	35,070
Serafim335m	52,619	23,319	14,027
ST MiniLM	30,563	13,206	**8,047**
Tucano	65,169	27,637	16,835

Plasticidade e Rigidez

Tabela: Número médio de *tokens* por palavra

Modelo	AG News PT	TuPy	ASSIN	ASSIN2	HateBR	Em Ambiente Real	Média
Albertina100M	2,098	2,186	2,143	2,046	2,418	2,265	2,193
Albertina900M	1,841	1,884	1,855	1,707	2,007	1,914	1,868
BERTimbau	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
BERTimbauLarge	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
Gemma	1,416	1,491	1,458	1,187	1,536	1,429	1,420
QWen	1,686	1,749	1,730	1,529	1,874	1,725	1,716
Serafim335M	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
ST MiniLM	1,460	1,536	1,434	1,308	1,624	1,461	1,471
Tucano	1,311	**1,484**	**1,271**	**1,162**	**1,525**	**1,326**	**1,347**

- Suposição comum:
  - Tokenizador em português é mais eficiente
  - Menor fragmentação gera um melhor desempenho

Análise dos *tokens*

Tabela: Número médio de *tokens* por palavra

Modelo	AG News PT	TuPy	ASSIN	ASSIN2	HateBR	Em Ambiente Real	Média
Albertina100M	2,098	2,186	2,143	2,046	2,418	2,265	2,193
Albertina900M	1,841	1,884	1,855	1,707	2,007	1,914	1,868
BERTimbau	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
BERTimbauLarge	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
Gemma	1,416	1,491	1,458	1,187	1,536	1,429	1,420
QWen	1,686	1,749	1,730	1,529	1,874	1,725	1,716
Serafim335M	**1,400**	1,644	1,363	1,207	1,626	1,468	1,451
ST MiniLM	1,460	1,536	1,434	1,308	1,624	1,461	1,471
Tucano	1,311	**1,484**	**1,271**	**1,162**	**1,525**	**1,326**	**1,347**

- Não foi possível encontrar correlação entre:
  - Ser monolíngue e gerar menos tokens
  - Melhor desempenho

Análise dos *tokens*

- Tucano gerou menos tokens sem resultados expressivos
- Albertina900M produziu mais tokens e teve bons resultados
- Tokenizadores intermediários tiveram melhores resultados

Análise dos *tokens*

Modelo	Tokenização				
	pulsava	preditiva	saudosa	fundamento	fake news
Morfologia	pulsava	preditiva	saudosa	fundamento	-
Albertina100M	pulsava	preditiva	saudosa	fundamento	fake news
Albertina900M	pulsava	preditiva	saudosa	fundamento	fake news
BERTimbau	pulsava	preditiva	saudosa	fundamento	fake news
BERTimbauLarge	pulsava	preditiva	saudosa	fundamento	fake news
Gemma	pulsava	preditiva	saudosa	fundamento	fake news
Qwen	pulsava	preditiva	saudosa	fundamento	fake news
Serafim335M	pulsava	preditiva	saudosa	fundamento	fake news
ST MiniLM	pulsava	preditiva	saudosa	fundamento	fake news
Tucano	pulsava	preditiva	saudosa	fundamento	fake news

- BERTimbau e Serafim mais próximos da morfologia
- Albertina possui menos dificuldade para empréstimos lexicais
- Gemma e ST MiniLM possuem um bom entendimento da língua

Dilema da *Tokenização*

- Modelos monolíngues:
  - Espaço de embedding menos restritivo
  - Maior capacidade de reorganização
  - Ganhos mais consistentes
- Modelos multilíngues:
  - Conhecimento inter-linguístico
  - Menor flexibilidade de adaptação
  - Propenso a degradações

Conclusão

Conclusão

- Modelos multilíngues são competitivos em linear-probing
- A especialização é benéfica
- Monolíngues dominam após fine-tuning
- Tokenizações monolíngues não são sempre superiores
- Não existe bala de prata

Trabalhos futuros

- Conjuntos de dados mais variados
- Testes específicos para entender a degradação do STS
- Criar métricas para medir a "plasticidade"dos modelos

Referências

Bibliography I

 DEVLIN, J.; CHANG, M.-W.; LEE, K.; TOUTANOVA, K. Bert: Pre-training of deep bidirectional transformers for language understanding. In: *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*. [S.l.: s.n.], 2019. p. 4171–4186.

 GARCIA, G. L.; PAIOLA, P. H.; MORELLI, L. H.; CANDIDO, G.; JúNIOR, A. C.; JODAS, D. S.; AFONSO, L. C. S.; GUILHERME, I. R.; PENTEADO, B. E.; PAPA, J. P. *Introducing Bode: A Fine-Tuned Large Language Model for Portuguese Prompt-Based Task*. 2024.

 GHOSH, K.; SENAPATI, A. Hate speech detection in low-resourced indian languages: An analysis of transformer-based monolingual and multilingual models with cross-lingual experiments. *Natural Language Processing*, v. 31, n. 2, p. 393–414, 2025.

 GOMES, L.; BRANCO, A.; SILVA, J.; RODRIGUES, J.; SANTOS, R. *Open Sentence Embeddings for Portuguese with the Serafim PT* encoders family*. 2024. Disponível em: <https://arxiv.org/abs/2407.19527>.

 HU, E. J.; SHEN, Y.; WALLIS, P.; ALLEN-ZHU, Z.; LI, Y.; WANG, S.; WANG, L.; CHEN, W. *LoRA: Low-Rank Adaptation of Large Language Models*. 2021. Disponível em: <https://arxiv.org/abs/2106.09685>.

Bibliography II


KOSTIć, M.; BATANOVIć, V.; NIKOLIć, B. Monolingual, multilingual and cross-lingual code comment classification. *Engineering Applications of Artificial Intelligence*, v. 124, p. 106485, 2023. ISSN 0952-1976. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0952197623006693>.


Maicon Domingues. *canarim-7b (Revision 08fdd2b)*. Hugging Face, 2023. Disponível em: <https://huggingface.co/dominguesm/canarim-7b>.


PETROV, A.; MALFA, E. L.; TORR, P.; BIBI, A. Language model tokenizers introduce unfairness between languages. In: OH, A.; NAUMANN, T.; GLOBERSON, A.; SAENKO, K.; HARDT, M.; LEVINE, S. (Ed.). *Advances in Neural Information Processing Systems*. Curran Associates, Inc., 2023. v. 36, p. 36963–36990. Disponível em: <https://proceedings.neurips.cc/paper_files/paper/2023/file/74bb24dca8334adce292883b4b651eda-Paper-Conference.pdf>.


PIRES, R.; ABONIZIO, H.; ALMEIDA, T. S.; NOGUEIRA, R. Sabiá: Portuguese large language models. In: _____. *Intelligent Systems*. Springer Nature Switzerland, 2023. p. 226–240. ISBN 9783031453922. Disponível em: <http://dx.doi.org/10.1007/978-3-031-45392-2_15>.


SANDERSON, G. *Mas o que é um GPT? Introdução visual aos Transformadores | Aprendizagem profunda, capítulo 5*. 2024. Disponível em: <https://youtu.be/wjZofJX0v4M?si=lV_5yFiSxa29LVku>.

Bibliography III

 SOUZA, F.; NOGUEIRA, R.; LOTUFO, R. Bertimbau: pretrained bert models for brazilian portuguese. In: *Intelligent Systems: 9th Brazilian Conference, BRACIS 2020, Rio Grande, Brazil, October 20–23, 2020, Proceedings, Part I*. [S.l.]: Springer, 2020. p. 403–417.

 TURING, A. M. I.—computing machinery and intelligence. *Mind*, LIX, n. 236, p. 433–460, 10 1950. ISSN 0026-4423. Disponível em: <https://doi.org/10.1093/mind/LIX.236.433>.

 VASWANI, A.; SHAZEER, N.; PARMAR, N.; USZKOREIT, J.; JONES, L.; GOMEZ, A. N.; KAISER, Ł.; POLOSUKHIN, I. Attention is all you need. *Advances in neural information processing systems*, v. 30, 2017.

 VIRTANEN, A.; KANERVA, J.; ILO, R.; LUOMA, J.; LUOTOLAHTI, J.; SALAKOSKI, T.; GINTER, F.; PYYSALO, S. *Multilingual is not enough: BERT for Finnish*. 2019. Disponível em: <https://arxiv.org/abs/1912.07076>.

 WU, S.; DREDZE, M. *Are All Languages Created Equal in Multilingual BERT?* 2020. Disponível em: <https://arxiv.org/abs/2005.09093>.

Obrigado pela atenção!

Dúvidas?